

UNIVERSIDAD POLITÉCNICA DE MADRID

**ESCUELA TÉCNICA SUPERIOR
DE INGENIEROS DE
TELECOMUNICACIÓN**



INSTITUTO DE ENERGÍA SOLAR



**MÁSTER UNIVERSITARIO EN
ENERGÍA SOLAR FOTOVOLTAICA
TRABAJO FIN DE MÁSTER**

**ESTIMACIÓN DE LA CANTIDAD DE
INSTALACIONES FV EN AUTOCONSUMO Y
GENERACIÓN ELÉCTRICA ESPERABLE
MEDIANTE PROCESADO DE IMÁGENES
AÉREAS**

MARÍA BAQUEDANO AÍSA

TUTOR: RUBÉN NÚÑEZ JÚDEZ

2024

RESUMEN

El autoconsumo fotovoltaico ha ganado protagonismo en España, impulsado por las políticas de transición energética y el interés por reducir la dependencia y el uso de los combustibles fósiles. Sin embargo, la falta de una cuantificación precisa de las instalaciones fotovoltaicas existentes y de su generación real plantea desafíos en cuanto a la planificación energética entre otras cuestiones.

Este proyecto aborda esta problemática mediante la implementación de una metodología para la detección de instalaciones fotovoltaicas y la estimación de su generación energética a partir de imágenes aéreas de alta resolución.

El desarrollo de una metodología sólida para la detección y estimación energética de estos sistemas puede tener un impacto significativo para alcanzar los objetivos de descarbonización, ya que no solo permite caracterizar el estado actual del autoconsumo, si no que este enfoque metodológico también ayuda al análisis para una planificación óptima de su crecimiento.

El trabajo se enmarca en el contexto de los municipios en territorios de transición justa afectados por el desmantelamiento de infraestructuras de generación eléctrica convencionales, donde se busca revitalizar la economía a través de la implementación de energías renovables y en particular generación distribuida.

Para la elaboración del método, se ha llevado a cabo una revisión exhaustiva de proveedores de imágenes aéreas de alta resolución para seleccionar aquellos que mejor se adaptan a la detección de instalaciones fotovoltaicas. Además, se han evaluado diferentes herramientas y modelos de detección de objetos que utilizan técnicas de machine learning, con el objetivo de identificar una solución aplicable al proyecto y eficiente para el reconocimiento de módulos fotovoltaicos en áreas urbanas y rurales. Asimismo, se han revisado y comparado distintas herramientas de simulación de sistemas fotovoltaicos para modelar la generación eléctrica de las instalaciones detectadas.

Los resultados del trabajo realizado proporcionan una caracterización de las instalaciones fotovoltaicas existentes en los municipios que forman parte del Convenio de Transición Justa de Aragón, así como una estimación de la generación esperable.

El proyecto ha demostrado la viabilidad de utilizar imágenes aéreas de alta resolución y modelos de machine learning para detectar instalaciones fotovoltaicas y estimar su producción energética. La metodología desarrollada sienta las bases para investigaciones que busquen caracterizar el estado actual del autoconsumo en otras regiones, así como planificar su futura expansión.

the current state of self-consumption in other regions, as well as to plan its future expansion.

PALABRAS CLAVE

Autoconsumo Fotovoltaico; Imágenes Aéreas; Modelos de Detección de Objetos; Energías Renovables; Territorios de Transición Justa

SUMMARY

Photovoltaic self-consumption has gained prominence in Spain, driven by energy transition policies and the interest in reducing dependency and use of fossil fuels. However, the lack of an accurate quantification of existing photovoltaic installations and their actual generation poses challenges in terms of energy planning among other matters.

This project addresses this problem by implementing a methodology for the detection of photovoltaic installations and the estimation of their energy generation from high resolution aerial imagery.

The development of a robust methodology for the detection and energy estimation of this systems can have a significant impact on achieving decarbonization goals, as it not only allows to characterize the current state of self-consumption, but this methodological approach also helps in the analysis for a optimal planning of its growth.

The work is framed in the context of municipalities in just transition territories affected by the dismantling of conventional power generation infrastructures, where the aim is to revitalize the economy through the implementation of renewable energies and in particular distributed generation.

For the method elaboration, an exhaustive review of high-resolution aerial imagery providers has been carried out in order to select those best suited to the detection of photovoltaic installations. In addition, different object detection tools and models using machine learning techniques have been evaluated in order to identify a solution applicable to the project and efficient for the recognition of photovoltaic modules in urban and rural areas. In addition, different photovoltaic system simulation tools have been reviewed and compared to model the power generation of the detected installations.

The results of the work carried out provide a characterization of the existing photovoltaic installations in the municipalities that are part of the Just Transition Agreement of Aragón, as well as an estimation of the expected generation.

The project has demonstrated the feasibility of using high-resolution aerial images and machine learning models to detect photovoltaic installations and estimate their energy production. The methodology developed lays the groundwork for research that seeks to characterize the current state of self-consumption in other regions, as well as to plan its future expansion.

KEYWORDS

Photovoltaic Self-Consumption; Aerial Imagery; Object Detection Models; Renewable Energies; Just Transition Territory

ÍNDICE DEL CONTENIDO

1. INTRODUCCIÓN Y OBJETIVOS	1
1.1. Contexto y motivación.....	1
1.2. Situación del autoconsumo fotovoltaico en España.....	1
1.3. Objetivos	5
1.4. Estructura del documento.....	5
2. ESTADO DEL ARTE.....	6
2.1. Evaluación de herramientas	6
2.1.1. Proveedores de imágenes de alta resolución.....	6
2.1.2. Herramientas de machine learning para la detección de objetos	8
2.1.3. Herramienta para la simulación del modelo de sistemas fotovoltaicos.....	11
2.2. Métricas y parámetros en la precisión de modelos de detección de objetos	13
2.3. Revisión bibliográfica sobre detección de instalaciones fotovoltaicas en imágenes aéreas ..	15
3. METODOLOGÍA.....	19
3.1. Selección de herramientas.....	19
3.1.1. Proveedor de imágenes: Google Maps Static.....	19
3.1.2. Herramienta de detección: Roboflow.....	19
3.1.3. Herramienta de simulación: PVlib.....	19
3.2. Evaluación del modelo de detección de instalaciones fotovoltaicas.....	21
3.2.1. Selección del modelo de detección	21
3.2.1. Área de estudio y obtención de imágenes	21
3.2.1. Pruebas de detección.....	23
3.3. Evaluación del modelo de estimación energética de instalaciones fotovoltaicas	27
3.3.1. Estimación del área de las detecciones	27
3.3.2. Estimación de la potencia instalada	27
3.3.3. Estimación de la generación	28
4. RESULTADOS	32
4.1. Detección de instalaciones fotovoltaicas en territorios de transición justa en Aragón	32
4.2. Estimación de la potencia instalada y la generación fotovoltaica del territorio de transición justa en Aragón	34
5. CONCLUSIONES Y LÍNEAS FUTURAS.....	37
5.1. Conclusiones.....	37
5.2. Líneas futuras.....	38
6. BIBLIOGRAFÍA.....	39
ANEXO A. ENTORNO DE TRABAJO Y REPOSITORIO	41

ANEXO B. CÓDIGO.....	43
ÍNDICE DE FIGURAS.....	52
ÍNDICE DE TABLAS.....	53
LISTA DE ACRÓNIMOS.....	54

1. INTRODUCCIÓN Y OBJETIVOS

1.1. CONTEXTO Y MOTIVACIÓN

El autoconsumo fotovoltaico ha experimentado un crecimiento exponencial en España, especialmente en las áreas residenciales e industriales. Sin embargo, este crecimiento plantea desafíos en cuanto a la cuantificación de instalaciones y la estimación precisa de su producción energética.

En regiones donde existen convenios y nudos de transición justa tras el cierre de centrales térmicas de carbón y explotaciones mineras, el autoconsumo juega un papel crucial en la dinamización de una economía verde y una democratización de la generación eléctrica.

Este proyecto surge de la necesidad de detectar y caracterizar las instalaciones fotovoltaicas existentes y estimar su impacto energético para una mayor optimización de la operación del sistema eléctrico y una adecuada planificación de las inversiones en infraestructuras fotovoltaicas.

1.2. SITUACIÓN DEL AUTOCONSUMO FOTOVOLTAICO EN ESPAÑA

El autoconsumo fotovoltaico ha emergido como una pieza clave en la transición energética de España, reflejando un crecimiento exponencial en los últimos años. Este crecimiento ha sido impulsado por varios factores, entre los que destacan los elevados precios de la electricidad, las políticas de fomento de energías renovables y las ayudas del Plan de Recuperación de la Unión Europea (UE) [1]. Sin embargo, este avance no ha estado exento de desafíos, particularmente en lo que respecta a la cuantificación precisa de las instalaciones y la estimación de su producción, lo que es crucial para la estabilidad y planificación del sistema eléctrico nacional. En este apartado se realiza una revisión de la situación actual del autoconsumo en España, destacando cifras recientes, tendencias, y la problemática inherente a la falta de un registro exhaustivo y actualizado de estas instalaciones.

- Cifras y tendencias del autoconsumo fotovoltaico en España

En los últimos años, el autoconsumo fotovoltaico ha alcanzado cifras récord en España. Según informes de la Asociación de Empresas de Energías Renovables (APPA) y la Unión Española Fotovoltaica (UNEF), 2022 fue un año sin precedentes, con la instalación de entre 2507 MW (dato UNEF) y 2649 MW (dato APPA) [2].

En 2023, según UNEF, se instalaron 1.706 MW de autoconsumo fotovoltaico en España, mientras que APPA reporta 1.943 MW [3], de los cuales en torno al 30% se correspondería a instalaciones residenciales y el 70% al sector industrial, tal y como se muestra en la Figura 1. Hay una diferencia notable entre los datos de las asociaciones, especialmente en el autoconsumo residencial, lo que destaca la importancia de contar con un registro oficial de autoconsumo en España para mejorar la coordinación y gestión del sistema.

Aunque este total representa una disminución de aproximadamente un 30% respecto a 2022, en parte debido a barreras regulatorias, económicas, una moderación de los precios de la electricidad y limitaciones de infraestructura, sigue siendo un 70% superior a lo instalado en 2021, lo que subraya el crecimiento continuo del sector a pesar de los desafíos recientes.




Figura 1. Evolución de la potencia de autoconsumo instalada (MW). Fuente APPA [4].

Este crecimiento ha llevado a que la capacidad total de autoconsumo en España alcance los 7 GW en 2023, superando la potencia instalada en centrales nucleares en el país. En términos de generación, el autoconsumo superaría los 7 GWh en 2023, lo que equivale al 3% de la demanda eléctrica nacional y representa un aumento del 60% respecto al año anterior.

- Problemática en la cuantificación de instalaciones de autoconsumo y la estimación de su generación eléctrica

Uno de los desafíos más críticos del autoconsumo en España es la falta de un registro preciso y actualizado de las instalaciones existentes y su capacidad de producción. Para seguir su evolución, es necesario basarse en las estimaciones que proporcionan las empresas del sector. A medida que el volumen de potencia de autoconsumo adquiere un peso considerable en el sistema eléctrico, se hace cada vez más importante que actores clave como Red Eléctrica de España (REE) y otros operadores del sistema tengan una estimación certera y en tiempo real de esta potencia.

El Gobierno español ha implementado medidas para mejorar la contabilización del autoconsumo, como la creación del Registro Administrativo de Autoconsumo de Energía Eléctrica (RADNE) [5]. Sin embargo, este registro aún presenta limitaciones significativas, y no refleja con exactitud la gran cantidad de instalaciones ya existentes. Según reportes recientes, a pesar de las mejoras en la recolección de datos, sigue sin saberse a ciencia cierta cuánta capacidad de autoconsumo fotovoltaico está operativa en España, y existe una gran discrepancia entre los datos oficiales y las estimaciones del sector [6] [7]. Esta falta de información precisa complica la planificación y la gestión del sistema eléctrico, especialmente en un contexto de crecimiento continuo donde el autoconsumo tiene un peso considerable en relación a la demanda eléctrica nacional.

Contar con estadísticas fiables y actualizadas es imprescindible, no solo para la gestión diaria del sistema eléctrico, sino también para evitar el desperdicio de energía renovable excedentaria que podría ser vertida a la red pero que actualmente se limita debido a barreras regulatorias y técnicas.

- Planes de crecimiento y perspectivas futuras

El Plan Nacional Integrado de Energía y Clima (PNIEC) y la Hoja de Ruta del Autoconsumo establecen metas ambiciosas para el desarrollo del autoconsumo en España. Aunque el ritmo de nuevas instalaciones ha mostrado signos de desaceleración, el autoconsumo sigue siendo una de las principales palancas para alcanzar los objetivos de descarbonización del país.

El PNIEC ha establecido como objetivo que el país cuente con una capacidad instalada de entre 9.000 MW y 14.000 MW para 2030 [8]. La Hoja de Ruta del Autoconsumo aprobada por el Ministerio para la Transición Ecológica y el Reto Demográfico (MITECO), cuyo itinerario se muestra en la Figura 2, incluye 37 medidas para fomentar el autoconsumo, mejorar la competitividad industrial y promover la adopción de sistemas de autoconsumo colectivo.

A pesar de un posible estancamiento temporal, el potencial de crecimiento del autoconsumo en España sigue siendo considerable, especialmente en sectores como el residencial y el comercial. La saturación de ciertos segmentos del mercado podría ser superada con políticas adecuadas y la modernización de la infraestructura eléctrica.




Figura 2. Itinerario de la Hoja de Ruta del Autoconsumo para el periodo 2021-2030. Fuente: MITECO [9].

- Impacto del autoconsumo en la red eléctrica

El aumento de las instalaciones de autoconsumo, entre otros factores como altos precios de la electricidad y el incremento de la eficiencia energética, ha tenido un impacto significativo en la demanda de electricidad de la red. Según informes recientes, la revolución del autoconsumo ha contribuido a reducir la demanda de electricidad a su nivel más bajo en 20 años [10]. Este cambio, si bien beneficioso desde una perspectiva de sostenibilidad y eficiencia energética, también plantea desafíos para la estabilidad del sistema eléctrico.

Como se puede apreciar en la Figura 3, la reducción de la demanda en las horas centrales del día, que oscila entre un 10% y un 15% desde 2018, podría atribuirse en gran medida al autoconsumo. Esta disminución, que representa entre 3 y casi 5 GWh, tiene implicaciones significativas para el equilibrio energético en España.

Eventos anómalos como eclipses solares [11] [12], o incluso la vulnerabilidad en la ciberseguridad de los servicios en la nube de los inversores fotovoltaicos como se ha visto recientemente en algunas noticias [13] [14], ponen de manifiesto la importancia de tener una comprensión clara y precisa de la generación de energía de las instalaciones de autoconsumo. Durante un eclipse solar, la generación fotovoltaica puede disminuir drásticamente, lo que podría poner en riesgo la estabilidad de la red si no se gestiona adecuadamente. Estos eventos subrayan la necesidad de contar con datos en tiempo real y modelos predictivos que permitan anticipar y mitigar los efectos de tales contingencias.




Figura 3. Promedio horario de la demanda en España 2018-2023 (MWh). Fuente: REE, Optimize Energy.

El autoconsumo fotovoltaico ha transformado el panorama energético en España, ofreciendo una alternativa sostenible y económica para hogares y negocios. Sin embargo, el crecimiento exponencial de estas instalaciones ha revelado importantes desafíos en la cuantificación y monitorización de su impacto en el sistema eléctrico. A medida que España avanza hacia un modelo energético más descentralizado y sostenible, será crucial mejorar los sistemas de registro y estimación de la capacidad de autoconsumo, así como abordar las barreras que limitan su expansión. La capacidad de gestionar de manera efectiva este crecimiento será determinante para asegurar la estabilidad y eficiencia del sistema eléctrico nacional en el futuro.

1.3. OBJETIVOS

Los principales objetivos definidos para este proyecto son los siguientes:

- Detectar instalaciones fotovoltaicas en áreas urbanas y rurales utilizando imágenes aéreas de alta resolución y herramientas de machine learning.
- Estimar la generación eléctrica de las instalaciones detectadas mediante la simulación de sistemas fotovoltaicos con herramientas de simulación especializadas.
- Caracterizar el estado actual del autoconsumo en los municipios que forman parte del Convenio de Transición Justa de Aragón, evaluando su capacidad instalada y su contribución a la generación de energía renovable.
- Proponer una metodología robusta que pueda ser replicada en otras regiones para facilitar el seguimiento del autoconsumo en el contexto de la transición energética.
- Trabajar en la dirección de los Objetivos de Desarrollo Sostenible (ODS), más concretamente el ODS 7 “Energía asequible y no contaminante”, que busca garantizar el acceso a una energía asequible, segura, sostenible y moderna para todos, y el ODS 11 “Ciudades y comunidades sostenibles”, que pone el foco en la energía sostenible como clave para el desarrollo de ciudades inteligentes y sostenibles.

1.4. ESTRUCTURA DEL DOCUMENTO

A continuación, se describe la estructura que sigue el trabajo:

- Capítulo 1: Introducción y Objetivos
 - Situación del autoconsumo fotovoltaico en España en el contexto del proyecto
- Capítulo 2: Estado del arte
 - Evaluación de herramientas existentes para el desarrollo de las tareas
 - Caracterización de métricas de precisión de modelos de detección de objetos
 - Revisión bibliográfica sobre la de detección de instalaciones fotovoltaicas en imágenes aéreas
- Capítulo 3: Metodología
 - Selección de herramientas para las distintas fases del proyecto
 - Evaluación del modelo de detección de instalaciones fotovoltaicas
 - Evaluación del modelo de estimación de la generación eléctrica
- Capítulo 4: Resultados
 - Detección de instalaciones fotovoltaicas y estimación de su generación en el territorio de transición justa de Aragón
- Capítulo 5: Conclusiones y líneas futuras
 - Resumen y conclusiones del trabajo realizado
 - Descripción de las futuras líneas del proyecto
- Bibliografía y Anexos

2. ESTADO DEL ARTE

2.1. EVALUACIÓN DE HERRAMIENTAS

En este apartado se realiza una revisión de los servicios y herramientas existentes con los que desarrollar la metodología del proyecto. Primero se analizarán proveedores de imágenes aéreas, posteriormente herramientas para la detección de instalaciones fotovoltaicas sobre las imágenes descargadas, y finalmente una herramienta de simulación de sistemas fotovoltaicos para la estimación de la generación.

2.1.1. Proveedores de imágenes de alta resolución

La selección de un proveedor de imágenes de alta resolución es crucial para la eficacia de un sistema de detección de instalaciones fotovoltaicas basado en machine learning (ML). En este apartado, se evalúan diversas plataformas y servicios que ofrecen imágenes aéreas y de alta resolución, considerando aspectos clave como la resolución espacial, la resolución temporal, y la accesibilidad.

- EO Browser Sentinel Hub (Sentinel)

Sentinel-2, el satélite principal usado en EO Browser¹, ofrece una resolución espacial de hasta 10 metros por píxel en algunas bandas, lo que es adecuado para la detección de estructuras grandes, pero no suficiente para identificar con precisión instalaciones fotovoltaicas de menor tamaño.

Los satélites Sentinel-2 tienen una revisita global de 5 días, lo que proporciona una buena resolución temporal para monitorear cambios en la superficie terrestre.

EO Browser permite la visualización y descarga de imágenes de forma gratuita a través de una interfaz web. También ofrece una interfaz de programación de aplicaciones (Application Programming Interface, API) para la integración con otros sistemas.

- Maxar

Maxar² cuenta con algunas de las imágenes comerciales de mayor resolución disponibles, llegando hasta 30 cm por píxel, lo que es ideal para la identificación precisa de instalaciones fotovoltaicas.

La resolución temporal depende de las solicitudes específicas, Maxar ofrece imágenes casi en tiempo real bajo demanda, lo que es ventajoso para proyectos que requieren datos actualizados constantemente.

Las imágenes pueden ser adquiridas a través de una API o mediante un servicio personalizado. Este servicio es de pago, y los costes pueden ser elevados, especialmente para imágenes de alta resolución.

- Planet

Planet³ proporciona imágenes con una resolución espacial de hasta 3 metros por píxel con su flota de satélites Dove, y hasta 50 cm con sus satélites SkySat, lo que es adecuado para la identificación de instalaciones fotovoltaicas de tamaño mediano a grande.

El proveedor ofrece una resolución temporal muy alta, con imágenes diarias disponibles gracias a su amplia constelación de satélites.

¹ [Sentinel Hub EO Browser \(sentinel-hub.com\)](https://sentinel-hub.com)

² [Maxar Intelligence & Maxar Space Systems](#)

³ [Planet Labs: Satellite Imagery & Earth Data Analytics](#)

Se puede acceder a las imágenes a través de su plataforma o mediante una API, lo que facilita su integración en aplicaciones de ML. Es un servicio de pago, con diferentes planes de suscripción según las necesidades del usuario. Cuenta con un plan de estudiantes con acceso gratuito a determinados servicios, pero no incluye la descarga de imágenes del satélite de SkySat.

- Google Maps Static

Las imágenes de Google Maps suelen tener una resolución espacial limitada a uno o varios metros por píxel en función del nivel de zoom, lo que puede no ser suficiente para identificar con precisión instalaciones fotovoltaicas pequeñas o medianas.

La resolución temporal es baja, con actualizaciones irregulares de imágenes, lo que no garantiza la disponibilidad de datos recientes.

Las imágenes pueden ser accedidas mediante la API de Google Maps Static⁴, de uso gratuito hasta un cierto número de solicitudes, con tarifas aplicables para uso extendido.

- Google Earth

Google Earth⁵ ofrece imágenes con resolución espacial variable, similar a la de Google Maps, pero con la opción de acceder a imágenes históricas que pueden ofrecer mayor detalle en algunas áreas.

La resolución temporal es limitada y las actualizaciones no son frecuentes ni consistentes.

Las imágenes son accesibles gratuitamente a través de la interfaz de Google Earth Pro, que permite la descarga de imágenes, pero con limitaciones de resolución. Gratuito para uso general.

- SAS Planet

SAS Planet⁶ es una herramienta que permite acceder a imágenes satelitales de múltiples fuentes, incluyendo Google Earth, Bing Maps, y otros servicios, lo que significa que tanto la resolución espacial como la resolución temporal varían según la fuente seleccionada.

Es un software de escritorio gratuito y proporciona acceso sin restricciones, pero depende de la disponibilidad de imágenes de los servicios integrados.

- QGIS

QGIS⁷ no es un proveedor de imágenes en sí, sino una plataforma SIG que permite la integración de imágenes de diferentes proveedores. Al igual que SAS Planet, la resolución espacial, así como la temporal, dependen de las capas de imágenes que se integren.

Gratuito y de código abierto, QGIS permite la integración de múltiples servicios de imágenes satelitales y la personalización a través de plugins.

⁴ [Descripción general | Maps Static API | Google for Developers](#)

⁵ [Google Earth](#)

⁶ [Download SAS Planet 2024: High-Resolution Satellite Images & Maps | SAS Planet \(geojamal.com\)](#)

⁷ [Spatial without Compromise · QGIS Web Site](#)

- OpenAerial Map

OpenAerial Map⁸ es una plataforma colaborativa que ofrece acceso a imágenes aéreas y satelitales de diversas fuentes, con una resolución espacial que puede variar significativamente.

La resolución temporal es irregular, ya que depende de la disponibilidad y actualización de las imágenes proporcionadas por la comunidad. Gratuito, con acceso a través de una interfaz web o mediante API.

A continuación, se muestra una tabla que recoge un resumen de las principales características para cada uno de los proveedores de imágenes:

Tabla 1. Comparativa de proveedores de imágenes aéreas.

Proveedor	EO Browser (Sentinel-2)	Maxar	Planet (SkySat)	Google Maps Static / Google Earth	SAS Planet / QGIS	Open Aerial Map
Resolución espacial	10m/pixel	30cm/pixel	50cm/pixel	1-5m/ pixel	Depende de la fuente	Depende de la comunidad
Resolución temporal	5 días	Bajo demanda	Diaria	Indefinida, poca frecuencia	Depende de la fuente	Depende de la comunidad
Accesibilidad	Gratuito, API/ web	De pago, API/ web	De pago, API /web	Gratuito, interfaz/API	Gratuito, interfaz	Gratuito, API /web

Para un proyecto de detección de instalaciones fotovoltaicas mediante herramientas de machine learning, la elección del proveedor de imágenes depende de las necesidades específicas de la tarea en términos de resolución espacial y temporal, así como del presupuesto disponible. Maxar y Planet destacan por ofrecer las imágenes de mayor resolución, aunque a un coste elevado, siendo ideales para la identificación precisa de instalaciones de cualquier tamaño. Sentinel Hub ofrece una solución con buena resolución temporal pero una resolución espacial insuficiente. Por otro lado, herramientas como Google Maps/Earth, SAS Planet o QGIS proporcionan plataformas flexibles y gratuitas, pueden ser útiles para la visualización y análisis preliminar, pero tienen algunas limitaciones en términos de resolución y actualización de imágenes.

2.1.2. Herramientas de machine learning para la detección de objetos

En este apartado se realiza una evaluación de diferentes herramientas, librerías y proyectos de machine learning que han sido considerados para la detección de instalaciones fotovoltaicas en imágenes aéreas. El objetivo principal de esta evaluación es identificar una herramienta que sea sencilla de utilizar, aplicable al proyecto, y que ofrezca resultados precisos en la detección de módulos fotovoltaicos.

⁸ [OpenAerialMap](https://openaerialmap.org/)

- PyTorch:

PyTorch⁹ es una librería open-source desarrollada por Facebook AI Research, que ha ganado popularidad en la comunidad de investigación por su flexibilidad y facilidad para desarrollar modelos de deep learning (DL).

Se destaca por ofrecer una gran libertad para definir arquitecturas personalizadas de redes neuronales. Sin embargo, requiere un nivel técnico avanzado, ya que los usuarios deben tener una comprensión sólida de los conceptos de ML, optimización y manejo de datos para implementar modelos complejos.

- TensorFlow:

TensorFlow¹⁰, desarrollado por Google, es otra de las librerías de ML más utilizadas, especialmente en entornos de producción y despliegue a gran escala.

Ofrece una amplia gama de herramientas para la construcción y despliegue de modelos, incluyendo integración con plataformas de cloud computing y dispositivos móviles, sin embargo, su curva de aprendizaje es empinada y requiere un alto nivel de conocimientos técnicos para su uso y configuración.

- Keras:

Keras¹¹ es una librería open-source diseñada para ser una interfaz de alto nivel sobre TensorFlow y otras. Su objetivo principal es simplificar el proceso de desarrollo de modelos de DL al proporcionar una interfaz intuitiva y amigable.

Aunque es más accesible, Keras sigue requiriendo conocimientos avanzados en ML, especialmente cuando se utilizan modelos personalizados o arquitecturas complejas. Es ideal para usuarios que necesitan un balance entre facilidad de uso y capacidad de construir modelos potentes.

- MATLAB: “Detección de objetos en imágenes satelitales grandes utilizando deep learning”¹²

MATLAB proporciona un enfoque guiado para la detección de objetos en imágenes aéreas, utilizando su caja de herramientas de DL y visión por computadora.

Es conocido por su facilidad de uso, especialmente para usuarios que prefieren un entorno gráfico y no desean trabajar con código extenso. Proporciona un flujo de trabajo simplificado, ideal para usuarios con poca experiencia en programación.

Puede ser útil para proyectos académicos y prototipos rápidos donde la simplicidad y el soporte técnico son prioritarios, sin embargo, el coste del software y las licencias podrían ser una limitación.

⁹ [PyTorch](#)

¹⁰ [TensorFlow](#)

¹¹ [Keras: Deep Learning for humans](#)

¹² [Object Detection in Large Satellite Imagery Using Deep Learning - MATLAB & Simulink - MathWorks España](#)

- Roboflow: “Modelos y datasets de detección de paneles solares”¹³

Roboflow ofrece una plataforma gratuita para entrenar y desplegar modelos de detección de objetos, con varios datasets preentrenados específicamente para la detección de módulos fotovoltaicos.

Su interfaz gráfica de fácil uso permite cargar datasets, entrenar modelos y realizar inferencias sin necesidad de escribir código. Este proveedor ofrece una solución "plug-and-play" con un alto nivel de personalización a través de la plataforma web y API, proporcionando una buena combinación de simplicidad y flexibilidad.

- Proyecto alojado en GitHub: “dbaofd/solar-panels-detection”¹⁴

Este proyecto utiliza un modelo de detección de objetos entrenado en TensorFlow para identificar módulos fotovoltaicos en imágenes aéreas.

El proyecto proporciona scripts para el preprocesamiento de datos, entrenamiento del modelo y la inferencia. Sin embargo, requiere familiaridad con TensorFlow y el manejo de datos de entrenamiento personalizados, por lo que puede ser complejo para usuarios sin experiencia previa en DL.

- Proyecto alojado en GitHub: “alan-turing-institute/solar-panel-detection”¹⁵

Este trabajo es parte de una iniciativa más amplia de investigación en el Alan Turing Institute, utilizando una combinación de técnicas de ML y DL.

Aunque el trabajo tiene un enfoque bien estructurado, puede ser un desafío para los usuarios sin experiencia avanzada en deep learning debido a la necesidad de configurar entornos complejos y manejar grandes conjuntos de datos.

- Proyecto alojado en GitHub: “TorrBorr/solar-panel-locator”¹⁶

Esta herramienta utiliza técnicas de deep learning con un enfoque práctico para localizar módulos fotovoltaicos sobre imágenes aéreas.

El código cuenta con instrucciones sobre cómo preparar los datos y ejecutar el modelo. Es adecuado para proyectos que requieren una solución más directa y fácil de implementar, aunque la precisión puede ser menor en comparación con herramientas más avanzadas.

- Proyecto alojado en GitHub: “msabvid/Solar-Panels-Detection”¹⁷

Este proyecto utiliza un enfoque basado en YOLO para la detección de módulos fotovoltaicos en imágenes aéreas.

YOLO es particularmente útil para aplicaciones en tiempo real donde la velocidad de detección es crucial, pero el código implementado requiere de conocimientos intermedios en DL.

¹³ [Identify Solar Panels in Aerial Imagery with Computer Vision \(roboflow.com\)](https://roboflow.com)

¹⁴ [GitHub - dbaofd/solar-panels-detection: Automatically detect solar panels on satellite imagery.](https://github.com/dbaofd/solar-panels-detection)

¹⁵ [GitHub - alan-turing-institute/solar-panel-detection: Solar Panel Detection \(Turing Climate Action Call\)](https://github.com/alan-turing-institute/solar-panel-detection)

¹⁶ [GitHub - TorrBorr/solar-panel-locator: Find solar panels in high resolution satellite images](https://github.com/TorrBorr/solar-panel-locator)

¹⁷ [GitHub - msabvid/Solar-Panels-Detection: Detection and location of Solar Panels in aerial images using U-Net](https://github.com/msabvid/Solar-Panels-Detection)

Tanto PyTorch, TensorFlow, como Keras son herramientas poderosas para la detección de objetos, pero requieren un nivel técnico avanzado. Los usuarios con experiencia en programación y en deep learning pueden aprovechar estas librerías para crear modelos altamente personalizados y eficientes. Sin embargo, para proyectos donde se busca una solución más aplicable y sencilla, plataformas como Roboflow o MATLAB destacan como las opciones más accesibles, ya que ofrecen soluciones de fácil uso y personalizables sin la necesidad de un conocimiento profundo de las librerías subyacentes.

Para usuarios con conocimientos intermedios en deep learning que buscan un equilibrio entre facilidad de uso y capacidad de personalización, proyectos como “TorrBorr/solar-panel-locator” y “msabvid/Solar-Panels-Detection” proporcionan una estructura clara y modelos efectivos.

Por otro lado, para proyectos que requieren un alto grado de precisión y tienen acceso a recursos computacionales avanzados, proyectos como “alan-turing-institute/solar-panel-detection” o “dbaofd/solar-panels-detection” podrían ser más adecuados, aunque su complejidad puede ser un obstáculo para usuarios menos experimentados.

2.1.3. Herramienta para la simulación del modelo de sistemas fotovoltaicos

En esta sección, se presentan algunas de las herramientas más relevantes para la estimación de la generación en instalaciones fotovoltaicas. Estas herramientas serán esenciales para realizar una estimación de la potencia instalada y la generación esperada sobre las instalaciones fotovoltaicas detectadas por los modelos de machine learning, considerando factores como la radiación solar, la orientación e inclinación de los módulos fotovoltaicos y otros parámetros de diseño.

- PVsyst

PVsyst¹⁸ es un software comercial ampliamente utilizado en la industria para el diseño y la simulación de sistemas fotovoltaicos. Ofrece una interfaz gráfica intuitiva y una amplia base de datos meteorológica.

Está diseñado para ser utilizado por ingenieros y diseñadores de sistemas fotovoltaicos, con una interfaz de usuario que facilita la entrada de datos y la simulación de diferentes configuraciones de sistemas. No requiere conocimientos de programación, lo que lo hace accesible para una audiencia más amplia.

Es ideal para proyectos que necesitan una herramienta completa y validada para la simulación de sistemas fotovoltaicos, incluyendo análisis de pérdidas, efectos de sombras, y optimización de diseños.

PVsyst es reconocido por su precisión y ha sido validado extensivamente a través de su uso en la industria. La documentación es exhaustiva, con manuales detallados y soporte técnico disponible.

- PVLib

PVLib¹⁹ es una librería de Python para la simulación de sistemas fotovoltaicos. Ofrece una amplia gama de funciones para modelar la irradiancia, la energía esperable, y el comportamiento de los sistemas fotovoltaicos a lo largo del tiempo.

¹⁸ [PVsyst – Photovoltaic software](#)

¹⁹ [pvlib python — pvlib python 0.11.0 documentation \(pvlib-python.readthedocs.io\)](#)

Esta herramienta está orientada a usuarios con conocimientos en programación, específicamente en Python. Si bien es muy flexible y se integra fácilmente en flujos de trabajo personalizados, requiere cierto nivel de familiaridad con scripting y análisis de datos.

Es ideal para proyectos que buscan una integración directa con otros modelos o sistemas automatizados. Su capacidad para ser personalizada y escalada lo hace especialmente útil en aplicaciones de investigación y desarrollo de software.

PVLib utiliza modelos físicos detallados para calcular la irradiancia y la producción energética, lo que le permite ofrecer estimaciones precisas siempre que se disponga de datos de entrada fiables. La documentación es extensa y bien organizada, con ejemplos que facilitan la implementación de diferentes escenarios de simulación.

- System Advisor Model (SAM)²⁰

SAM es una herramienta de simulación desarrollada por el National Renewable Energy Laboratory (NREL) que permite a los usuarios modelar el rendimiento y la viabilidad económica de proyectos de energía renovable, incluyendo sistemas fotovoltaicos.

La herramienta combina una interfaz gráfica amigable con la posibilidad de personalizar simulaciones utilizando scripts. Es accesible para usuarios sin experiencia en programación, pero también permite a usuarios avanzados ajustar modelos y parámetros según sus necesidades específicas.

Es especialmente útil para proyectos que no solo necesitan estimar la generación de energía, sino también analizar la viabilidad económica de las instalaciones fotovoltaicas. Es una herramienta versátil que puede ser utilizada tanto en el diseño preliminar como en el análisis de proyectos en operación.

SAM ofrece modelos precisos y validados para la simulación del rendimiento de sistemas fotovoltaicos. La documentación es excelente, incluyendo guías de usuario, tutoriales en video y una comunidad activa que facilita el intercambio de conocimientos y mejores prácticas.

La elección de la herramienta de simulación de sistemas fotovoltaicos dependerá de los requisitos específicos del proyecto, el nivel de conocimiento técnico y la necesidad de personalización.

PVLib es una buena opción para proyectos que requieren una integración flexible con modelos personalizados o que usan Python en el flujo de trabajo. Es ideal para investigadores y desarrolladores que cuentan con experiencia en programación y buscan una herramienta potente y adaptable.

Por otro lado, PVsyst ofrece una solución completa para la simulación de sistemas fotovoltaicos con un enfoque en la precisión y la facilidad de uso. Es adecuado para diseñadores e ingenieros que necesitan una herramienta confiable y ampliamente aceptada en la industria, sin necesidad de programar.

Finalmente, SAM se destaca por su versatilidad, permitiendo tanto la simulación técnica como el análisis económico de proyectos fotovoltaicos. Es una excelente opción para proyectos que requieren una evaluación completa, y su interfaz gráfica lo hace accesible para todos los usuarios.

²⁰ [Home - System Advisor Model - SAM. \(nrel.gov\)](https://www.nrel.gov/sam/)

2.2. MÉTRICAS Y PARÁMETROS EN LA PRECISIÓN DE MODELOS DE DETECCIÓN DE OBJETOS

En este apartado se describen las métricas y parámetros clave que afectan al desempeño de los modelos de detección de objetos, como aquellos utilizados para identificar instalaciones fotovoltaicas en imágenes aéreas. Estas métricas son esenciales para evaluar y ajustar los modelos, asegurando que su precisión y fiabilidad sean óptimas para el análisis de datos geoespaciales [15].

En la siguiente tabla se definen las clases y tipos de predicción de un modelo de detección:

Tabla 2. Clases y predicciones de los modelos de detección

Clase	Predicción	Descripción
Positiva	Positivo Verdadero (True Positive, TP)	Objeto correctamente identificado por el modelo como parte de la clase de interés. Indicador directo de la efectividad del modelo para detectar correctamente los objetos que se desea identificar.
	Positivo Falso (False Positive, FP)	Objeto erróneamente identificado por el modelo que no pertenece a la clase de interés. Minimizar los falsos positivos es crucial para mejorar la precisión del modelo.
Negativa	Negativo Verdadero (True Negative, TN)	El modelo correctamente no detecta un objeto en una región donde no hay ningún objeto de interés. Aunque menos discutido en muchos análisis, es importante para evaluar la robustez del modelo en áreas sin objetos de interés.
	Negativo Falso (False Negative, FN)	El modelo erróneamente no detecta un objeto que realmente pertenece a la clase de interés. Reducir los falsos negativos es esencial para asegurar que el modelo no omita objetos importantes.

A continuación, se describen los principales parámetros que afectan el desempeño de los modelos de detección:

- Resolución espacial de las imágenes:

Factor determinante en la precisión de los modelos de detección. Imágenes con alta resolución permiten identificar detalles finos, como pequeños módulos fotovoltaicos en cubiertas, mientras que imágenes de baja resolución pueden llevar a detecciones incompletas o erróneas.

- Nivel de zoom:

Influye en la capacidad del modelo para detectar objetos. Un zoom más alto puede ofrecer una vista más detallada de una región específica, mejorando la precisión de la detección de objetos pequeños, pero puede limitar el campo de visión y aumentar el número de imágenes necesarias para cubrir grandes áreas.

- Umbral de confianza (Threshold):

Valor a partir del cual el modelo considera que un objeto detectado es válido. Ajustar el umbral de confianza afecta directamente a las tasas de positivos verdaderos, positivos falsos y negativos falsos. Un umbral bajo puede incrementar la detección de objetos verdaderos (TP), pero también aumenta la posibilidad de identificar erróneamente otros elementos como objetos de interés (FP). Un umbral alto reduce la probabilidad de falsos positivos (FP), pero puede resultar en una menor tasa de detección de objetos verdaderos (TP).

Para evaluar y ajustar los modelos de detección de objetos, se utilizan varias métricas de precisión que permiten cuantificar su desempeño y tomar decisiones sobre la configuración óptima de los parámetros. Las métricas más comunes incluyen:

- Precisión (Precision):

Se define como el número de positivos verdaderos dividido por el total de predicciones positivas (positivos verdaderos más positivos falsos). Esta métrica indica qué porcentaje de las detecciones realizadas por el modelo son correctas.

$$Precision = \frac{Positivos\ Verdaderos}{Positivos\ Verdaderos + Positivos\ Falsos} = \frac{TP}{TP + FP}$$

Un modelo con alta precisión tiene una baja tasa de falsos positivos, lo que es crítico en aplicaciones donde la precisión es más importante que la cantidad total de detecciones.

- Recuperación (Recall)

La recuperación o recall mide la capacidad del modelo para detectar todos los objetos de interés presentes en la imagen. Se calcula como el número de positivos verdaderos dividido por el total de objetos reales (verdaderos positivos más falsos negativos).

$$Recall = \frac{Positivos\ Verdaderos}{Positivos\ Verdaderos + Negativos\ Falsos} = \frac{TP}{TP + FN}$$

Un modelo con alto recall es capaz de identificar la mayoría de los objetos relevantes, aunque pueda incrementar la tasa de falsos positivos.

- Puntuación F1:

La puntuación F1 es una media ponderada de la precisión y la recuperación. Los valores varían de 0 a 1, donde 1 corresponde a la precisión más alta.

$$F1 = \frac{Precision * Recall}{[Precision + Recall]/2}$$

- Curvas PR (Precision-Recall):

Las curvas PR son una herramienta gráfica que muestra la relación entre la precisión y la recuperación para diferentes niveles de umbral de confianza. Estas curvas permiten identificar el punto óptimo donde el modelo equilibra adecuadamente la precisión y el recall. Un área bajo la curva PR más alta indica un mejor desempeño global del modelo.

La selección y ajuste de los parámetros son fundamentales para el desarrollo de un modelo de detección de objetos efectivo. Factores como la resolución de las imágenes, el nivel de zoom y el umbral de confianza influyen significativamente en el rendimiento del modelo. Las métricas de evaluación, como la precisión, el recall, y las curvas PR, proporcionan una comprensión profunda del rendimiento del modelo, permitiendo ajustar los parámetros para lograr un equilibrio óptimo entre la detección correcta y la minimización de errores. Este enfoque sistemático asegura que los modelos desarrollados en el proyecto sean robustos, precisos y adecuados para su aplicación en la detección de instalaciones fotovoltaicas.

2.3. REVISIÓN BIBLIOGRÁFICA SOBRE DETECCIÓN DE INSTALACIONES FOTOVOLTAICAS EN IMÁGENES AÉREAS

En este apartado se presentan los principales hallazgos de una revisión bibliográfica centrada en proyectos que han abordado la detección de instalaciones fotovoltaicas a través de imágenes aéreas de alta resolución. A continuación, se resumen las ideas clave de cada estudio.

- "Automatic Detection of Solar PV Arrays in High Resolution Aerial Imagery" [16]

El estudio aborda la detección automática de conjuntos fotovoltaicos en imágenes aéreas de alta resolución utilizando el clasificador de aprendizaje automático Random Forest. El enfoque se centra en la identificación de patrones y características que distinguen a los módulos fotovoltaicos de otros objetos en un entorno urbano.

El proyecto destaca por haber sido testado en un conjunto de datos de imágenes aéreas en color (RGB) recogidas sobre la ciudad estadounidense de Fresno, California. Las imágenes cubren un área espacial total de 135 km², tienen una resolución espacial de 0,3 metros por píxel, y todas han sido orto-rectificadas. Además, el artículo cuenta con un apartado extenso sobre métricas de rendimiento del modelo, como la curva de precisión y recuperación que se muestra en la siguiente figura.




Figura 4. Ilustración de una curva PR.

El trabajo concluye que la combinación de técnicas de preprocesamiento de imágenes y algoritmos de ML permite una detección precisa de las instalaciones fotovoltaicas, reduciendo significativamente la tasa de detecciones erróneas.

- "A deep convolutional neural network and a random forest classifier for solar photovoltaic array detection in aerial imagery" [17]

Este estudio propone una metodología para la detección de módulos fotovoltaicos en imágenes aéreas utilizando una combinación de una red neuronal convolucional profunda (Convolutional Neural Network, CNN) y un clasificador de bosque aleatorio (Random Forest, RF). Para llevar a cabo esta investigación se utiliza el mismo conjunto de imágenes descrito en el artículo anterior. El objetivo principal es mejorar la precisión de la detección al combinar las fortalezas de ambos enfoques: la capacidad de las CNN para extraer características complejas y la eficiencia de los bosques aleatorios para la clasificación.

En la Figura 4 se muestra la arquitectura de detección del estudio. La primera etapa es un detector RF que identifica las ubicaciones candidatas de los módulos fotovoltaicos en las imágenes aéreas. Se extraen parches de imágenes alrededor de cada ubicación detectada y se envían a una clasificador CNN que identifica las falsas detecciones.




Figura 5. Arquitectura de detección en cascada empleada en el trabajo “A deep convolutional neural network and a random forest classifier for solar photovoltaic array detection in aerial imagery”.

El análisis concluye que la combinación de CNN y RF logra una alta precisión en la detección de módulos fotovoltaicos, superando a los métodos tradicionales con una metodología robusta que puede ser adaptada para diferentes tipos de imágenes aéreas.

- "A solar panel dataset of very high-resolution satellite imagery to support the Sustainable Development Goals" [18]

En este artículo se emplea un conjunto de datos de imágenes satelitales de muy alta resolución para la detección de módulos fotovoltaicos. El objetivo es mejorar la precisión en la detección de instalaciones fotovoltaicas, especialmente en áreas residenciales. El conjunto de datos incluye imágenes satelitales de 31 cm y 15.5 cm de resolución de Maxar Technologies, anotadas para la detección de módulos fotovoltaicos.

La tarea de investigación destaca la importancia de disponer de datos de alta resolución para mejorar la precisión en la detección de pequeños objetos, dada la dificultad de detectar módulos fotovoltaicos especialmente en áreas residenciales debido a su tamaño reducido y su variabilidad en la orientación. En la siguiente figura se el proceso de adquisición de imágenes para la detección y anotación de módulos fotovoltaicos del estudio.




Figura 6. Proceso de partición y anotación de datos en el trabajo “A solar panel dataset of very high-resolution satellite imagery to support the Sustainable Development Goals”.

El conjunto de datos es único en su tipo, ya que ofrece imágenes de muy alta resolución junto con anotaciones detalladas, lo que lo convierte en un recurso valioso para entrenar y validar modelos de detección de instalaciones fotovoltaicas.

- "DeepSolar: A Machine Learning Framework to Efficiently Construct a Solar Deployment Database in the United States" [19]

DeepSolar es una herramienta de Deep learning desarrollada por la Universidad de Stanford para identificar y segmentar instalaciones fotovoltaicas a partir de imágenes aéreas de Google Maps, con el objetivo de construir una base de datos de instalaciones fotovoltaicas en los Estados Unidos. Además de la detección, el estudio analiza factores socioeconómicos y ambientales que influyen en la densidad de despliegue de sistemas fotovoltaicos.




Figura 7. DeepSolar. Un marco de aprendizaje automático para construir eficientemente una base de datos de despliegue solar en Estados Unidos.

La herramienta DeepSolar logra una alta precisión en la detección y segmentación de módulos fotovoltaicos, y su análisis revela cómo factores como la radiación solar y los ingresos familiares influyen en la adopción de la energía solar fotovoltaica. La base de datos creada es un recurso valioso para la investigación y la planificación de políticas energéticas.

- "Detection of Solar Panels in Satellite Images UC3M" [20]

En este proyecto realizado en la Universidad Carlos III de Madrid, se implementó un sistema de detección de módulos fotovoltaicos utilizando imágenes aéreas y técnicas de DL con la metodología de detección de objetos You Only Look Once (YOLO).

En la Figura 8 se muestra el procesamiento de datos del proyecto, donde se utiliza una serie de imágenes anotadas para el entrenamiento y la validación del modelo, e imágenes de Google Maps para su evaluación.



Figura 8. Metodología de entrenamiento y evaluación del proyecto "Detection of Solar Panels in Satellite Images UC3M".

El trabajo demostró la viabilidad de utilizar imágenes aéreas combinadas con técnicas avanzadas de ML para la detección automática de módulos fotovoltaicos. Los resultados obtenidos fueron prometedores, con un alto grado de precisión y recuperación en la detección y puntuaciones F1 superiores a 0.8.

Los estudios revisados proporcionan una sólida base de conocimiento, enfoques diversos y recursos valiosos para la detección de instalaciones fotovoltaicas mediante imágenes aéreas. Las técnicas avanzadas de detección de objetos, el uso de imágenes de alta resolución y la combinación de diferentes enfoques de machine learning son elementos clave que podrían mejorar significativamente la precisión y eficacia de las detecciones.

Además, el análisis de factores socioeconómicos y la estimación de la producción de estas instalaciones podrían ser incorporados para enriquecer el análisis de impacto de las instalaciones detectadas, proporcionando una visión más integral del despliegue y la adopción de energía solar fotovoltaica.

3. METODOLOGÍA

3.1. SELECCIÓN DE HERRAMIENTAS

La selección de las herramientas para el desarrollo del proyecto se ha basado en criterios de facilidad de uso, integración en un entorno de programación común (Python), y la capacidad para cumplir con los objetivos específicos del proyecto. A continuación, se describen las herramientas seleccionadas y los detalles de su elección.

3.1.1. Proveedor de imágenes: Google Maps Static

Google Maps Static ha sido seleccionado como el proveedor de imágenes aéreas de alta resolución para este proyecto. Este servicio permite la descarga de imágenes estáticas de Google Maps a través de su API, proporcionando flexibilidad en la selección de áreas geográficas y niveles de zoom.

La API de Google Maps Static ofrece una solución accesible y económica para la obtención de imágenes. Se integra fácilmente con Python, lo que permite automatizar el proceso de descarga de imágenes y facilita la gestión de grandes volúmenes de datos de forma eficiente.

A pesar de la limitación en la resolución temporal debido a la actualización incierta de las imágenes, la capacidad de ajustar el nivel de zoom permite obtener imágenes con una resolución espacial suficiente para la detección precisa de instalaciones fotovoltaicas. Esto es crucial para el análisis y modelado posterior.

3.1.2. Herramienta de detección: Roboflow

Roboflow ha sido elegido como la herramienta principal para la detección de instalaciones fotovoltaicas en las imágenes obtenidas. Esta plataforma proporciona acceso a varios modelos de detección preentrenados que son altamente efectivos para identificar módulos fotovoltaicos en imágenes aéreas de alta resolución.

La plataforma se destaca por su interfaz intuitiva y su facilidad de uso, lo que permite a los usuarios cargar, preprocesar y etiquetar imágenes con mínima complejidad técnica. Además, la disponibilidad de modelos preentrenados reduce significativamente el tiempo de configuración inicial.

La API de Roboflow permite la integración directa con Python, lo que facilita la implementación de un flujo de trabajo automatizado donde las imágenes descargadas pueden ser procesadas y analizadas de manera continua. Esta capacidad es fundamental para mantener la coherencia y eficiencia en el análisis de grandes conjuntos de datos.

Aunque se utiliza un modelo preentrenado, Roboflow permite ajustar y mejorar los modelos según las necesidades del proyecto, ofreciendo un equilibrio óptimo entre simplicidad y personalización.

3.1.3. Herramienta de simulación: PVlib

PVLib es la herramienta seleccionada para la estimación de la generación eléctrica de las instalaciones fotovoltaicas detectadas. Esta librería de Python es ampliamente utilizada para la simulación de sistemas fotovoltaicos, proporcionando modelos físicos detallados y funciones para el análisis de rendimiento.

Se trata de una biblioteca bien establecida y continuamente desarrollada, lo que garantiza su fiabilidad y precisión en la simulación de sistemas fotovoltaicos. Su capacidad para manejar datos meteorológicos y modelar con precisión la irradiancia solar y el rendimiento del sistema la convierte en una opción ideal para este proyecto.

PVLib se integra perfectamente en el entorno de Python, lo que permite una integración fluida junto con las herramientas seleccionadas previamente para llevar a cabo la estimación de producción energética de las instalaciones detectadas.

La flexibilidad de PVLib permite ajustar los modelos y parámetros según las características específicas de las instalaciones detectadas, lo que mejora la precisión de las estimaciones de generación eléctrica. Además, su naturaleza de código abierto ofrece la posibilidad de adaptar y extender la funcionalidad según las necesidades del proyecto.

La elección de Google Maps Static, Roboflow, y PVLib responde a la necesidad de integrar herramientas efectivas y robustas en un único entorno de trabajo, utilizando Python en Jupyter Notebook como plataforma de desarrollo. Esta integración no solo facilita la automatización del proceso, sino que también asegura que cada etapa, desde la adquisición de imágenes hasta la detección y evaluación de instalaciones fotovoltaicas, sea realizada con herramientas que maximicen la precisión y eficiencia del proyecto.

3.2. EVALUACIÓN DEL MODELO DE DETECCIÓN DE INSTALACIONES FOTOVOLTAICAS

Uno de los objetivos principales del proyecto es identificar de manera precisa las instalaciones fotovoltaicas a partir de imágenes aéreas. Para ello, se ha realizado una evaluación exhaustiva de varios modelos de detección preexistentes, disponibles en la plataforma Roboflow. A continuación, se detalla el proceso de selección del modelo óptimo, las pruebas realizadas con diferentes niveles de zoom y umbrales de confianza, y los resultados obtenidos que han guiado la configuración final del modelo de detección.

3.2.1. Selección del modelo de detección

En primer lugar, se evaluaron tres modelos de detección de instalaciones fotovoltaicas disponibles en la plataforma de Roboflow. En la Figura 9 se muestra un ejemplo de detección para cada uno de los modelos evaluados, donde aparece resaltado el nivel de confianza con el que los modelos son capaces de detectar las instalaciones.



Figura 9. Evaluación de modelos de detección de instalaciones fotovoltaicas. a) Solar Panel Detector - SHH7N²¹ b) Solar Panel Detector – IMVOH²². c) Solar PV Panel Detection²³.

El tercer modelo, Solar PV Panel Detection, fue seleccionado debido a su mejor rendimiento general en las pruebas iniciales. Este modelo demostró una mayor precisión en la identificación de módulos fotovoltaicos en diferentes contextos de imágenes aéreas, lo que lo hizo el candidato ideal para la siguiente fase de pruebas en detalle.

3.2.1. Área de estudio y obtención de imágenes

Para evaluar en detalle el modelo seleccionado, se eligió un área de 1 km² en el barrio de Montecanal, situado al suroeste de la ciudad de Zaragoza (Aragón, España). Esta zona residencial se caracteriza por un alto número de casas adosadas, por lo que, debido a la mayor superficie de tejados disponible y el nivel adquisitivo de los residentes, se esperaba una alta densidad de instalaciones fotovoltaicas, haciendo de esta área un escenario ideal para la evaluación del modelo.

²¹ <https://universe.roboflow.com/solarpaneldetection-ltpzl/solar-panel-detector-shh7n>

²² <https://universe.roboflow.com/ariel-drabkin-tifgg/solar-panel-detector-imvoh>

²³ <https://universe.roboflow.com/whereareyousolarpanel/solar-pv-panel-detection>

En la siguiente figura se muestra una vista aérea de la zona evaluada, cuyo centro se sitúa en las coordenadas latitud, longitud: 41.629543°, -0.938692°. En la Figura 11, se exponen varias imágenes ampliadas sobre el centro del área evaluada, donde a modo de ejemplo, se puede observar a simple vista la existencia de estas instalaciones de autoconsumo.



Figura 10. Imagen aérea de la ubicación del área de evaluación del proyecto, resaltada en rojo



Figura 11. Imágenes ampliadas del área de evaluación del proyecto. Instalaciones fotovoltaicas resaltadas en verde.

Con el objetivo de evaluar el modelo de detección, se descargaron imágenes del área mencionada utilizando la API de Google Maps Static en tres niveles de zoom: 18, 19, y 20. Estos niveles de zoom proporcionaron resoluciones aproximadas de 175m, 95m, y 50m por imagen, respectivamente.

La descarga de estas imágenes se ha implementado en un código de Python, creando una malla de coordenadas en torno a la ubicación central del área evaluada en función de la resolución espacial de las imágenes para cada nivel de zoom, y realizando un barrido para cubrir el área deseada. El código se encuentra disponible en el Anexo B, y la descarga de las imágenes queda recogida en el apartado “Barrido imágenes GOOGLE MAPS STATIC”.

3.2.1. Pruebas de detección

Una vez descargadas las imágenes para cada uno de los niveles de zoom, se realizaron detecciones variando el nivel de confianza o threshold del modelo, desde 80% hasta 60%, y en el caso particular del zoom 19 hasta un threshold de 50%. Para ello, se hizo uso de la API de Roboflow mediante un código implementado en Python. El código se encuentra disponible en el Anexo B, y la detección de las instalaciones queda recogida en el apartado “Detecciones Roboflow”.

Para cada una de las detecciones, se ha realizado una inspección manual y se han anotado el número de positivos verdaderos, positivos falsos y negativos falsos, y con ello se han calculado las métricas de precisión (precision), recuperación (recall) y la métrica F1, descritas con anterioridad. En las siguientes tablas se detallan los resultados obtenidos.

Tabla 3. Número de positivos verdaderos, positivos falsos y negativos falsos en función del nivel de zoom de las imágenes y el threshold del modelo.

Threshold	zoom 18			zoom 19			zoom 20		
	TruePos	FalsePos	FalseNeg	TruePos	FalsePos	FalseNeg	TruePos	FalsePos	FalseNeg
0.8	2	0	129	67	8	90	111	40	96
0.75	4	1	127	77	13	80	126	61	81
0.7	7	1	124	89	23	68	134	85	73
0.65	12	3	119	95	27	62	143	105	64
0.6	15	5	116	100	31	57	151	126	56
0.55	-	-	-	110	44	47	-	-	-
0.5	-	-	-	113	53	44	-	-	-

Tabla 4. Métricas de precisión, recall y F1 en función del nivel de zoom de las imágenes y el threshold del modelo.

Threshold	zoom 18			zoom 19			zoom 20		
	Recall	Precision	F1	Recall	Precision	F1	Recall	Precision	F1
0.8	0.015	1.000	0.030	0.427	0.893	0.578	0.536	0.735	0.620
0.75	0.031	0.800	0.059	0.490	0.856	0.623	0.609	0.674	0.640
0.7	0.053	0.875	0.101	0.567	0.795	0.662	0.647	0.612	0.629
0.65	0.092	0.800	0.164	0.605	0.779	0.681	0.691	0.577	0.629
0.6	0.115	0.750	0.199	0.637	0.763	0.694	0.729	0.545	0.624
0.55	-	-	-	0.701	0.714	0.707	-	-	-
0.5	-	-	-	0.720	0.681	0.700	-	-	-

Como se puede observar en las tablas de resultados, de manera genérica a medida que se disminuye el nivel de threshold aumenta la cantidad de detecciones, es decir aumenta el número de positivos verdaderos pero también el de falsos positivos, y por ello aumenta el recall pero disminuye la precisión en las detecciones. En las siguientes figuras se muestran los resultados de manera gráfica.




Figura 12. Curva PR para distintos niveles de zoom, representados con distintos colores, variando el nivel de threshold del modelo.




Figura 13. F1 para distintos niveles de zoom, representados con distintos colores, variando el nivel de threshold del modelo.

Para un nivel de Zoom 18, se descargaron y evaluaron un total de 25 imágenes abarcando un área de 1 km². La baja resolución resultó en un desempeño subóptimo del modelo, con una F1 significativamente inferior en comparación con los otros niveles de zoom. Esto se debe principalmente a que la resolución no era suficiente para distinguir adecuadamente las instalaciones fotovoltaicas, resultando en un bajo recall y F1.

En la siguiente figura se muestra un ejemplo del desempeño del modelo para un nivel de Zoom 18. Para niveles de threshold de 60%, 70%, y 80% respectivamente, se observa en el primero la detección de un positivo falso resaltado en color naranja, dos positivos verdaderos resaltados en color verde, y seis negativos falsos que no han sido identificados por el modelo resaltados en color rojo. Si aumentamos

el nivel de confianza al 70%, desaparece el positivo falso pero también desaparece uno de los positivos verdaderos. Por último, para el máximo nivel de confianza, desaparece el único positivo verdadero que quedaba.



Figura 14. Ejemplo de desempeño del modelo de detección para un Zoom 18. a) Threshold 60%. b) Threshold 70%. c) Threshold 80%.

El nivel de Zoom 19 requirió de la descarga y evaluación de 100 imágenes, proporcionando un equilibrio más adecuado entre la resolución y el número de imágenes necesarias. Al evaluar diferentes niveles de threshold, se observó que, aunque una reducción en el threshold aumentaba el recall, la precisión se mantenía alta, lo que llevó a una mejora general en la F1. El mejor resultado se obtuvo con un threshold del 55%, lo que sugiere que esta configuración permite capturar la mayoría de las instalaciones fotovoltaicas manteniendo una precisión aceptable.

En la Figura 15 se muestra un ejemplo del desempeño del modelo para un nivel de Zoom 19. Para niveles de threshold de 50%, 65% y 80% respectivamente, se observa en el primero la detección de un positivo falso resaltado en color naranja, dos positivos verdaderos resaltados en color verde, y dos negativos falsos que no han sido identificados por el modelo resaltados en color rojo. Si aumentamos el nivel de confianza al 65%, desaparece el positivo falso pero también desaparece uno de los positivos verdaderos. Por último, para el máximo nivel de confianza, desaparece parte del área detectada del único positivo verdadero que quedaba.



Figura 15. Ejemplo de desempeño del modelo de detección para un Zoom 19. a) Threshold 50%. b) Threshold 65%. c) Threshold 80%.

Para el mayor nivel de zoom se descargaron y evaluaron un total de 400 imágenes. Aunque el nivel de Zoom 20 resultó en un mayor recall, también incrementó significativamente los falsos positivos, lo que disminuyó la precisión general y redujo la métrica F1 en comparación con el zoom 19. A pesar de la alta resolución, la gran cantidad de imágenes necesarias y el incremento en falsos positivos hicieron que este nivel de zoom fuera menos eficiente.

En la siguiente figura se muestra un ejemplo del desempeño del modelo para un nivel de Zoom 20. Para niveles de threshold de 60%, 70% y 80% respectivamente, se observa en el primero la detección de dos positivos falsos resaltados en color naranja y un positivo verdadero resaltado en color verde. Si aumentamos el nivel de confianza al 70%, desaparece uno de los positivos falsos. Por último, para el máximo nivel de confianza, desaparece el único positivo falso que quedaba.



Figura 16. Ejemplo de desempeño del modelo de detección para un Zoom 20. a) Threshold 60%. b) Threshold 70%. c) Threshold 80%.

Finalmente, el nivel de Zoom 19 con un Threshold de 55% se sitúa como la configuración óptima para el modelo de detección. Esta estructura proporciona el mejor equilibrio entre precisión y recall, alcanzando un F1 máximo que asegura una alta fiabilidad en la detección de instalaciones fotovoltaicas. Esta elección se basa en la necesidad de mantener una precisión adecuada mientras se maximiza la detección de verdaderos positivos y se minimiza la cantidad de imágenes procesadas, optimizando así los recursos computacionales y el tiempo de análisis.

Esta configuración del modelo de detección se utilizará para llevar a cabo la evaluación del modelo de estimación energética sobre las instalaciones detectadas.

3.3. EVALUACIÓN DEL MODELO DE ESTIMACIÓN ENERGÉTICA DE INSTALACIONES FOTOVOLTAICAS

En esta sección se describe el proceso de evaluación del modelo desarrollado para la estimación de la generación de las instalaciones fotovoltaicas detectadas. A partir de las áreas estimadas por el modelo de detección seleccionado, se ha calculado la potencia instalada y, posteriormente, se han simulado los sistemas fotovoltaicos detectados utilizando la biblioteca PVLlib. A continuación se detallan las suposiciones realizadas, la metodología empleada, y se presentan los resultados de las simulaciones, incluyendo un análisis de sensibilidad para ver en la medida en que afectan los distintos parámetros clave en la simulación.

3.3.1. Estimación del área de las detecciones

El primer paso en la estimación del área consistió en determinar la relación entre píxeles y metros cuadrados (pixel/m^2) en las imágenes aéreas procesadas por el modelo de detección de Roboflow. Esta relación es crucial para convertir la detección de áreas en las imágenes en estimaciones precisas del área real de las instalaciones fotovoltaicas.

Se realizaron mediciones comparativas entre las detecciones obtenidas y las medidas reales tomadas en Google Earth. Este proceso permitió determinar la relación pixel/m^2 para el zoom seleccionado, y así convertir las áreas estimadas en píxeles por el modelo de Roboflow a metros cuadrados con mayor precisión.

Por otro lado, se ha tratado de estimar la orientación de las instalaciones mediante relaciones geométricas, sin embargo, esta no ha podido ser determinada con precisión debido a resultados incoherentes, por lo que más adelante se evaluará el uso de una orientación fija.

Para la superficie de 1 km^2 analizada anteriormente, se obtiene un área total de detección de aproximadamente 2681 m^2 , lo que corresponde al 0.27% de la superficie analizada

3.3.2. Estimación de la potencia instalada

Una vez estimada el área de las instalaciones detectadas, el siguiente paso fue calcular la potencia instalada según los módulos fotovoltaicos, es decir, la potencia pico de las instalaciones.

Para ello, se asumió un valor fijo para la eficiencia de los módulos fotovoltaicos, utilizando la definición:

$$\text{Potencia} = \text{Área} \times \text{Eficiencia}$$

Este enfoque simplifica el proceso de estimación y proporciona una base para las simulaciones energéticas subsecuentes.

Para la superficie anteriormente analizada se obtiene una potencia instalada en torno a los 536 kWp considerada una eficiencia del módulo del 20%. Dada la relación directa entre la eficiencia y la potencia, la variación que se daría en el caso de utilizar otro valor de eficiencia sería proporcional.

En la siguiente tabla se muestran los resultados de estimación de la potencia instalada para distintos valores de eficiencia del módulo:

Tabla 5. Estimación de la potencia instalada en función de la eficiencia del módulo fotovoltaico.

Eficiencia módulo	18.0%	18.5%	19.0%	19.5%	20.0%	20.5%	21.0%	21.5%	22.0%
Pdc [kW]	482.6	496.0	509.4	522.8	536.2	549.6	563.0	576.4	589.8

En la Figura 17 se muestra un histograma con la frecuencia de las potencias obtenidas para la superficie evaluada anteriormente dada una eficiencia del módulo del 20%. Debe tomarse en consideración que estos valores son el resultado de cada una de las detecciones, es decir, puede que una instalación esté compuesta por varias detecciones, por lo que este histograma no se corresponde exactamente con el tamaño de las instalaciones completas.




Figura 17. Histograma de potencia de las instalaciones fotovoltaicas detectadas.

3.3.3. Estimación de la generación

Para simular la producción de energía de las instalaciones fotovoltaicas detectadas, se utilizó la biblioteca PVLlib, que permite modelar el rendimiento de sistemas fotovoltaicos bajo diversas condiciones ambientales y de configuración del sistema. El código se encuentra disponible en el Anexo B, y la estimación de generación de las instalaciones queda recogida en el apartado “Estimación generación PVLlib”.

Para la configuración del modelo, se tienen en cuenta los siguientes parámetros y consideraciones:

- Datos Meteorológicos: Se interactúa con la API de PVGIS²⁴ para descargar un año meteorológico tipo (TMY), que proporciona datos climáticos históricos y típicos para la ubicación de interés, lo que permite una simulación precisa del rendimiento energético a lo largo del año.

²⁴ [JRC Photovoltaic Geographical Information System \(PVGIS\) - European Commission \(europa.eu\)](https://ec.europa.eu/eurostat/tgm/table.do?tab=table&init=1&language=en&plugin=1)

- **Orientación e Inclinación:** Dado que la orientación y la inclinación pueden influir significativamente en la generación de energía y no se han podido estimar con el modelo de detección, se realiza un análisis exhaustivo variando estos parámetros.
- **Modelado de Temperatura:** Se utiliza el modelo de temperatura de módulos fotovoltaicos adecuado para instalaciones residenciales instaladas en cubierta, con los parámetros de "sapm" en PVLlib, que asume un módulo de vidrio-polímero con aislamiento trasero.
- **Coeficiente Gamma:** Se define el coeficiente gamma que describe la variación de la potencia respecto a la variación de la temperatura, y se estudia su afección.
- **Eficiencia del Inversor y Pérdidas del Sistema:** Se definen valores típicos para la eficiencia del inversor y las pérdidas generales del sistema, y se estudia la sensibilidad de la generación con su variación.

Se utilizarán los valores típicos que aparecen en la Tabla 6 como parámetros de referencia para las simulaciones y el análisis de sensibilidad. En el caso particular de la orientación y la inclinación, se ha escogido una configuración específica para realizar el análisis y posteriormente se verá la influencia de estos parámetros en el rendimiento energético, sin embargo, estos valores son muy dependientes de cada instalación y al tratarse de sistemas de autoconsumo, estará mayormente ligado a la disposición de las cubiertas existentes.

Tabla 6. Parámetros de referencia²⁵.

Parámetros	Valor de referencia
Eficiencia módulo	20%
Orientación	180°
Inclinación	10°
Coef. Temp γ	-0.4%/°C
Eficiencia inversor	98%
Pérdidas del sistema	15%

Dada la superficie analizada con anterioridad y la configuración base con los parámetros de referencia, se estima una generación aproximada de 717126 kWh para una potencia instalada de 536 kWp, correspondiendo a una producción específica o índice de rendimiento final del sistema de 1337 kWh/kWp, lo que resulta en una estimación razonable para la ubicación seleccionada y los parámetros definidos.

Para evaluar el impacto de la orientación e inclinación en la estimación energética, se crea una matriz con diferentes combinaciones de estos parámetros. Los resultados de las simulaciones se presentan en forma de tabla, mostrando cómo varía la estimación energética en términos de generación anual y producción específica en función de la orientación y la inclinación de los módulos fotovoltaicos.

²⁵ La orientación con un ángulo azimut de 180° se corresponde con una orientación al sur verdadero para el hemisferio norte.

Tabla 7. Energía anual en función de la orientación y la inclinación.

inclinación / orientación	Energía anual generada, kWh						
	0°	5°	10°	15°	20°	25°	30°
90°	664862	662882	658274	651423	642897	632842	621628
105°	664862	670752	673765	674128	672174	667862	661744
120°	664862	678047	687978	694728	698594	699354	697448
135°	664862	684289	700078	712154	720776	725763	727348
150°	664862	689078	709311	725452	737627	745957	750187
165°	664862	692109	715107	733790	748147	758333	764456
180°	664862	693191	717126	736674	751788	762482	768847
195°	664862	692256	715293	733908	748194	758277	764166
210°	664862	689374	709685	725770	737805	745719	749585
225°	664862	684733	700659	712729	721124	725863	727336
240°	664862	678623	688803	695677	699378	700028	697882
255°	664862	671439	674855	675459	673397	668972	662538
270°	664862	663646	659597	653065	644504	634290	622686

Tabla 8. Producción específica en función de la orientación y la inclinación

inclinación / orientación	Producción específica, kWh/kWp						
	0°	5°	10°	15°	20°	25°	30°
90°	1240	1236	1228	1215	1199	1180	1159
105°	1240	1251	1257	1257	1254	1246	1234
120°	1240	1265	1283	1296	1303	1304	1301
135°	1240	1276	1306	1328	1344	1354	1357
150°	1240	1285	1323	1353	1376	1391	1399
165°	1240	1291	1334	1369	1395	1414	1426
180°	1240	1293	1337	1374	1402	1422	1434
195°	1240	1291	1334	1369	1395	1414	1425
210°	1240	1286	1324	1354	1376	1391	1398
225°	1240	1277	1307	1329	1345	1354	1357
240°	1240	1266	1285	1297	1304	1306	1302
255°	1240	1252	1259	1260	1256	1248	1236
270°	1240	1238	1230	1218	1202	1183	1161

Los resultados indican variaciones significativas en la producción de energía dependiendo de la orientación e inclinación. En general, se observa que la orientación hacia el sur con una inclinación cercana a los 30° maximiza la producción para la ubicación de estudio, como es de esperar en el hemisferio norte para una latitud en torno a los 42°.

Adicionalmente, se realizan simulaciones variando otros parámetros clave, como el coeficiente de temperatura, la eficiencia del inversor o las pérdidas del sistema (especial relevancia a las pérdidas por sombreado en instalaciones de autoconsumo debido a los objetos presentes en las cubiertas y los edificios cercanos, así como pérdidas eléctricas, pérdidas por suciedad, indisponibilidad...)

Tabla 9. Estimación energética en función del coeficiente de temperatura.

Coef. Temp. (%/°C)	0	-0.003	-0.0035	-0.004	-0.0045	-0.005
Eac (kWh)	820316	743196	730165	717126	704079	691023
Yf (kWh/kWp)	1530	1386	1362	1337	1313	1289
%var	-	-9.4%	-11.0%	-12.6%	-14.2%	-15.8%

Tabla 10. Estimación energética en función del coeficiente de la eficiencia del inversor.

Eficiencia inversor	1	0.99	0.98	0.97	0.96	0.95
Eac	731761	724443	717126	709808	702490	695173
Yf (kWh/kWp)	1365	1351	1337	1324	1310	1297
%var	-	-1.0%	-2.0%	-3.0%	-4.0%	-5.0%

Tabla 11. Estimación energética en función de las pérdidas del sistema.

Pérdidas sistema (%)	0	7.5	10	12.5	15	17.5	20
Eac	843677	780401	759309	738218	717126	696034	674942
Yf (kWh/kWp)	1573	1455	1416	1377	1337	1298	1259
%var	-	-7.5%	-10.0%	-12.5%	-15.0%	-17.5%	-20.0%

Este análisis permite identificar qué parámetros tienen un mayor impacto en la precisión de la estimación energética, lo que puede guiar futuras optimizaciones del modelo.

El modelo de estimación energética desarrollado ha demostrado ser una herramienta útil para predecir la generación de energía de las instalaciones fotovoltaicas detectadas. Aunque se han hecho simplificaciones, como asumir una orientación fija debido a la dificultad de estimarla con precisión, las simulaciones realizadas con PVLlib proporcionan una estimación razonable de la producción anual de energía. Los análisis de sensibilidad realizados han mostrado la importancia de una correcta configuración de los parámetros del sistema, especialmente en lo que respecta a la orientación e inclinación de los módulos fotovoltaicos, que será característica para cada zona a evaluar, lo que subraya la necesidad de considerar estos factores al implementar sistemas de predicción energética en la práctica.

4. RESULTADOS

4.1. DETECCIÓN DE INSTALACIONES FOTOVOLTAICAS EN TERRITORIOS DE TRANSICIÓN JUSTA EN ARAGÓN

Para la aplicación de la herramienta de detección y simulación desarrollada en este proyecto, se han seleccionado para su análisis 34 municipios en Aragón que forman parte del Convenio de Transición Justa de Aragón (CTJA). Esta región ha sido seleccionada por su importancia estratégica en el contexto de la transición energética y la reindustrialización de zonas afectadas por el cierre de la Central Térmica de Andorra y las distintas explotaciones mineras del territorio. El proyecto del Nudo Mudéjar, nudo de transición justa, busca impulsar la instalación de energías renovables, incluyendo el autoconsumo fotovoltaico, como motor para la dinamización económica y la creación de empleo local. En particular, el análisis se centra en caracterizar las instalaciones fotovoltaicas ya existentes en la zona y estimar su generación, con el fin de evaluar el impacto del autoconsumo en la región. [21] [22] [23]

Los nudos de transición justa forman parte de una estrategia impulsada por el MITECO, con el objetivo de mitigar los efectos socioeconómicos derivados del cierre de las plantas térmicas de carbón y fomentar el desarrollo sostenible de las regiones más afectadas. Estas zonas, tradicionalmente dependientes de la producción de energía a partir de combustibles fósiles, enfrentan retos significativos en términos de empleo y reactivación económica. Dentro de este contexto, se ha establecido un marco de actuación para reorientar su actividad hacia la generación de energías renovables y la implementación de tecnologías más limpias y sostenibles. [24]

En la siguiente figura se muestra una imagen de los 34 municipios para los que se va a realizar la detección de instalaciones fotovoltaicas y la estimación de su generación, de los cuales 33 se encuentran en la provincia de Teruel y 1 en la provincia de Zaragoza.




Figura 18. Delimitación del ámbito territorial del CTJA [25].

El autoconsumo es visto como un pilar fundamental para reducir la dependencia de la red eléctrica, mejorar la sostenibilidad energética local, disminuir los costes para los hogares y empresas, y democratizar la producción de energía. Entender cuánta energía se genera actualmente a través de instalaciones existentes es clave para planificar la futura expansión de este tipo de sistemas.

El análisis tiene como objetivo caracterizar el estado actual del autoconsumo en estos municipios, identificando las instalaciones existentes y estimando su generación eléctrica a través de las herramientas avanzadas de detección y modelado descritas con anterioridad.

Al mapear las instalaciones fotovoltaicas existentes, se podrá realizar una estimación de la capacidad instalada en estos municipios. Este análisis es esencial para entender el papel actual del autoconsumo en el territorio.

A través de la estimación de la generación actual basada en las instalaciones detectadas, podría no sólo conocerse la contribución actual del autoconsumo, sino también su potencial de crecimiento y el impacto de una mayor penetración de nuevas instalaciones en la región.

En conclusión, la selección de esta región dentro del contexto de los Nudos de Transición Justa responde a la necesidad de evaluar el impacto actual del autoconsumo fotovoltaico en estas regiones como posible punto de partida para el estudio del potencial real del autoconsumo como catalizador de cambio en una zona que representa los desafíos y oportunidades de la transición energética en España.

4.2. ESTIMACIÓN DE LA POTENCIA INSTALADA Y LA GENERACIÓN FOTOVOLTAICA DEL TERRITORIO DE TRANSICIÓN JUSTA EN ARAGÓN

Para llevar a cabo el análisis en la región descrita, se delimita el área a evaluar en cada uno de los municipios, tal y como se muestra en la Figura 19.




Figura 19. Área evaluada en el ámbito territorial del CTJA.

Se descargan las imágenes necesarias para cubrir el área deseada a través de la API de Google Maps Static, seleccionando un Zoom 19 dada su buena relación entre la resolución, los resultados del modelo de detección y la cantidad de imágenes a procesar.

En total se evalúa un área de aproximadamente 51 km², para lo que se descargan y procesan más de 6000 imágenes.

Una vez descargadas las imágenes, en una primera aproximación se realiza su procesado con el modelo de detección descrito de Roboflow para un nivel de threshold de 55%, nivel con el que se alcanzaba el mayor F1 en el apartado de evaluación del desempeño del modelo. Sin embargo, se observa que hay una gran cantidad de positivos falsos con grandes superficies detectadas, por lo que se opta por utilizar un nivel de threshold de 70% para conseguir unos resultados más conservadores, pero con una mayor precisión.

El modelo de detección definido arroja un total de 634 detecciones para las imágenes evaluadas, con un área total de detección de aproximadamente 32570 m².

Tras realizar las detecciones, se simula el modelo de estimación energética de PVLIB para una configuración con los parámetros de base que se muestran en la siguiente tabla:

Tabla 12. Parámetros de referencia del modelo de generación para el caso de estudio.

Parámetros	Valor de referencia
Eficiencia módulo	20%
Orientación	180°
Inclinación	10°
Coef. Temp γ	-0.4%/°C
Eficiencia inversor	98%
Pérdidas del sistema	15%

En la Tabla 13, se muestran los resultados obtenidos para cada uno de los municipios, incluyendo la capacidad instalada, las estimaciones energéticas y otros indicadores. El detalle de las detecciones se puede encontrar en el repositorio de GITHUB, descrito en el Anexo A.

Dada la superficie anteriormente analizada y la configuración con los parámetros de referencia, se estima una generación total anual de 8543 MWh para una potencia total instalada de 6.5 MWp, lo que se corresponde con una producción específica media de 1314 kWh/kWp, una estimación razonable para la región estudiada y los parámetros definidos.

Adicionalmente, se estima el ratio de potencia instalada por habitante [26] [27], siendo la media de aproximadamente 0.2 kWp por habitante y teniendo en cuenta que también se detectan instalaciones de autoconsumo industrial en la zona, lo que indica que aunque hay presencia de autoconsumo en la región, todavía tiene mucho margen de crecimiento.

El análisis de las instalaciones fotovoltaicas existentes en estos municipios es esencial para proporcionar una visión clara del estado actual del autoconsumo en una región clave para la transición justa en Aragón y en España. A medida que se planifica la instalación de más potencia renovable en el Nudo Mudéjar, es fundamental entender la situación de partida, ya que esta información permitirá tomar decisiones más informadas sobre dónde y cómo priorizar nuevas inversiones en infraestructura fotovoltaica. Este estudio podría contribuir a que los proyectos futuros se alineen mejor con los objetivos de reindustrialización y desarrollo sostenible de la región, maximizando su impacto social y económico.

Tabla 13. Resultados de la detección y la estimación de la generación de las instalaciones fotovoltaicas ubicadas en los municipios del CTJA.

Municipio	Coordenadas [°]	Habitantes [N°]	Área evaluada [km2]	Imágenes [N°]	Detecciones [N°]	Área detección [m2]	Pdc [kWp]	GHI anual [kWh/m2]	Eac [kWh]	Yf [kWh/kWp]	Ratio kWp/Hab.
Alacón	41.01981, -0.698703	212	0.81	100	3	351	70	1723	93989	1343	0.33
Albalate del Arzobispo	41.121554, -0.515787	1955	3.61	400	27	1408	281	1698	371187	1321	0.14
Alcorisa	40.894347, -0.38272	3243	3.6125	405	66	2986	596	1699	783364	1314	0.18
Alloza	40.96822, -0.527983	540	1	121	7	154	30	1677	40920	1364	0.06
Andorra	40.981157, -0.447835	7214	6.25	729	98	5143	1028	1751	1417001	1378	0.14
Ariño	41.030439, -0.592472	649	1	121	6	224	44	1679	58830	1337	0.07
Azaila	41.290196, -0.493849	98	0.64	81	0	0	0	1708	0	0	0.00
Berge	40.856475, -0.426617	226	0.49	64	0	0	0	1678	0	0	0.00
Calanda	40.944106, -0.232952	3759	4.41	529	101	7043	1408	1684	1835603	1304	0.37
Cañizar del Olivar	40.816455, -0.645385	103	0.25	36	1	31	6	1623	7956	1326	0.06
Castel de Cabra	40.802905, -0.69597	89	0.4225	49	2	27	5	1644	7208	1442	0.06
Castellote	40.797319, -0.321147	678	1.69	196	4	146	29	1652	37884	1306	0.04
Castelnou	41.227582, -0.3616	108	1	121	0	0	0	1732	0	0	0.00
Crivillén	40.883209, -0.576738	90	0.36	49	0	0	0	1596	0	0	0.00
Ejulve	40.774846, -0.554101	176	0.49	64	6	305	61	1639	78616	1289	0.35
Escatrón	41.287198, -0.323926	1174	2.25	256	13	540	108	1729	142140	1316	0.09
Escucha	40.792288, -0.809376	766	2.25	256	8	605	121	1693	161214	1332	0.16
Estercuel	40.855523, -0.634658	196	0.49	64	4	156	31	1647	40538	1308	0.16
Foz de Calanda	40.918644, -0.255352	279	1.13	145	4	326	64	1682	85133	1330	0.23
Gargallo	40.834032, -0.583617	91	0.36	49	5	788	157	1583	197124	1256	1.73
Híjar	41.174023, -0.444468	1797	2.89	324	10	365	73	1726	97289	1333	0.04
Jatiel	41.219833, -0.381632	46	0.2025	25	0	0	0	1728	0	0	0.00
Mata de los Olmos	40.864493, -0.518616	281	0.81	100	5	163	32	1599	41067	1283	0.11
Molinos	40.820917, -0.451858	225	0.49	64	1	18	3	1692	4959	1653	0.01
Montalbán	40.83282, -0.803388	1180	2.5	292	13	1622	324	1610	409782	1265	0.27
Oliete	40.999449, -0.673815	349	1	121	4	216	43	1703	57487	1337	0.12
Olmos	40.876734, -0.486543	119	0.36	49	2	451	90	1674	118908	1321	0.76
Palomar de Arroyos	40.779664, -0.749325	167	0.36	49	0	0	0	1641	0	0	0.00
Puebla de Híjar	41.216982, -0.463333	917	3.25	390	203	4889	976	1719	1279456	1311	1.06
Samper de Calanda	41.187488, -0.386979	725	1.21	144	5	233	46	1739	62358	1356	0.06
Seno	40.813096, -0.338411	41	0.25	36	0	0	0	1649	0	0	0.00
Urrea de Gaén	41.16085, -0.472682	447	1.21	144	4	371	74	1722	99247	1341	0.17
Utrillas	40.811299, -0.847508	3088	2.33	277	29	3868	773	1602	977055	1264	0.25
Vinaceite	41.271116, -0.581144	200	1.96	225	3	139	27	1682	36338	1346	0.14

5. CONCLUSIONES Y LÍNEAS FUTURAS

5.1. CONCLUSIONES

El autoconsumo fotovoltaico está en pleno auge en España, impulsado por las políticas energéticas que fomentan la generación distribuida y la independencia energética. Sin embargo, a pesar de este crecimiento, la cuantificación de instalaciones fotovoltaicas y la estimación precisa de su generación siguen siendo retos importantes para los agentes energéticos y las instituciones.

El proyecto ha abordado estas necesidades demostrando la viabilidad de utilizar imágenes aéreas y modelos de machine learning para la detección de instalaciones fotovoltaicas de autoconsumo, así como el uso de herramientas de simulación para el modelado de su producción energética.

Uno de los aspectos clave de este proyecto ha sido el uso de imágenes aéreas de alta resolución obtenidas a través de Google Maps Static. La calidad y resolución de estas imágenes han permitido aplicar modelos de detección de instalaciones fotovoltaicas con un alto grado de precisión. Durante la fase de evaluación de los modelos de detección en la plataforma Roboflow, se observó que la resolución espacial es fundamental para diferenciar instalaciones fotovoltaicas de otros objetos en tejados y áreas urbanas. El análisis ha demostrado que niveles de zoom demasiado bajos reducen significativamente la capacidad de detección debido a la falta de detalle, mientras que niveles de zoom muy altos pueden incrementar los positivos falsos.

La precisión de los modelos de detección implementados ha sido otro factor crucial en el proyecto. Se realizaron pruebas con diferentes umbrales de confianza para evaluar el rendimiento del modelo seleccionado. Los resultados mostraron que, al reducir el nivel de threshold, se incrementaba el recall, aunque también se aumentaba el número de positivos falsos. El análisis refuerza la importancia de ajustar correctamente los parámetros del modelo de detección para obtener resultados con un equilibrio óptimo en función del grado de precisión que se quiera lograr.

En cuanto al modelado de los sistemas fotovoltaicos y la estimación de la generación energética, se utilizó la librería de PVLib, que ha demostrado ser una herramienta precisa y versátil, capaz de simular diferentes escenarios de producción energética en función de múltiples parámetros. La capacidad de interactuar con la API de PVGIS para obtener datos meteorológicos históricos ha añadido un nivel extra de fiabilidad en la simulación de la generación de las instalaciones fotovoltaicas detectadas. Además, el análisis de sensibilidad realizado ha permitido identificar los parámetros que más influyen en la producción de energía, lo que subraya la importancia de contar con datos precisos sobre la configuración de los sistemas para realizar estimaciones de generación más exactas.

La implementación de esta metodología en los municipios sujetos al Convenio de Transición Justa de Aragón, ha permitido obtener una estimación detallada de la potencia instalada y la generación energética en la región, así como otros indicadores de interés.

En resumen, el proyecto ha contribuido de manera significativa al análisis del estado actual del autoconsumo fotovoltaico en el territorio analizado, proporcionando una metodología robusta para la detección y caracterización de estas instalaciones. Los resultados obtenidos son de gran relevancia para planificar futuras expansiones de autoconsumo en la región, con el objetivo de maximizar el impacto positivo en la economía local y contribuir a los objetivos de descarbonización del país.

Este proyecto sienta las bases para futuros estudios que busquen monitorear el crecimiento del autoconsumo en otras regiones y optimizar la integración de energías renovables en el sistema eléctrico español.

5.2. LÍNEAS FUTURAS

Algunas líneas futuras de investigación que podrían enriquecer los resultados obtenidos son:

- Mejora del modelo de detección para el logro de una mayor precisión y rendimiento.
- Barrido temporal de la detección de instalaciones fotovoltaicas para determinar el año de instalación y su evolución a lo largo del tiempo.
- Estimación precisa de la orientación e inclinación de los módulos fotovoltaicos a partir de las imágenes, utilizando herramientas geométricas más avanzadas.
- Mejora en la proyección del área detectada para ajustar las estimaciones en función de la inclinación de las superficies.
- Estudio de la eficiencia de los módulos fotovoltaicos e incorporación de datos sobre la degradación de las instalaciones a lo largo del tiempo para mejorar la precisión en las estimaciones de generación futura teniendo en cuenta el año de su instalación.

Estas futuras líneas de trabajo permitirán una caracterización aún más detallada del autoconsumo en España, así como una estimación de la generación más precisa y resultados con una mayor fiabilidad.

6. BIBLIOGRAFÍA

- [1] «IDAE, Instituto para la Diversificación y Ahorro de la Energía,» [En línea]. Available: <https://www.idae.es/ayudas-y-financiacion/para-energias-renovables-en-autoconsumo-almacenamiento-y-termicas-sector/estado-de-las-convocatorias-por-comunidad-autonoma-rd-4772021-autoconsumo-y-almacenamiento#:~:text=El%20programa%20RD%20477%2F2021%20para%20.> [Último acceso: Septiembre 2024].
- [2] A. B. F., «"Retos, barreras y caída de un 30% en el ritmo de instalaciones de autoconsumo", Energías Renovables,» 17 Enero 2024. [En línea]. Available: <https://www.energias-renovables.com/autoconsumo/retos-barreras-y-caida-de-un-30-20240117.> [Último acceso: Septiembre 2024].
- [3] P. S. Molina, «"La necesidad de un registro único de autoconsumo en España", PV Magazine,» 31 Enero 2024. [En línea]. Available: [https://www.pv-magazine.es/2024/01/31/la-necesidad-de-un-registro-unico-de-autoconsumo-en-espana/.](https://www.pv-magazine.es/2024/01/31/la-necesidad-de-un-registro-unico-de-autoconsumo-en-espana/) [Último acceso: Septiembre 2024].
- [4] APPA, «Informe Anual de Autoconsumo Fotovoltaico,» 2023.
- [5] «RADNE, Registro Administrativo de Autoconsumo de Energía Eléctrica,» [En línea]. Available: [https://energia.serviciosmin.gob.es/Radne/.](https://energia.serviciosmin.gob.es/Radne/) [Último acceso: Septiembre 2024].
- [6] A. M. Vélez, «"El Gobierno exigirá a las eléctricas más datos sobre la evolución del autoconsumo ante el boom de instalaciones", elDiario.es,» 8 Enero 2023. [En línea]. Available: [https://www.eldiario.es/economia/gobierno-exigira-electricas-datos-evolucion-autoconsumo-boom-instalaciones_1_9843162.html.](https://www.eldiario.es/economia/gobierno-exigira-electricas-datos-evolucion-autoconsumo-boom-instalaciones_1_9843162.html) [Último acceso: Septiembre 2024].
- [7] «"¿Cuánto autoconsumo fotovoltaico hay en España?", Maldita.es,» 3 Abril 2023. [En línea]. Available: [https://maldita.es/clima/20230403/cuanto-autoconsumo-solar-fotovoltaico-espana/.](https://maldita.es/clima/20230403/cuanto-autoconsumo-solar-fotovoltaico-espana/) [Último acceso: Septiembre 2024].
- [8] MITECO, «Plan Nacional Integrado de Energía y Clima 2021-2030,» 2020.
- [9] MITECO, «Hoja de Ruta del Autoconsumo,» 2021.
- [10] REE, «Evolución de la demanda,» 2023. [En línea]. Available: <https://www.sistemaelectrico-ree.es/informe-del-sistema-electrico/demanda/evolucion-demanda.> [Último acceso: Septiembre 2024].
- [11] A. Fischer, «"Potential effect of the 2024 solar eclipse on solar energy production", PV Magazine,» 1 Abril 2024. [En línea]. Available: [https://www.pv-magazine.com/2024/04/01/potential-effect-of-the-2024-solar-eclipse-on-solar-energy-production/.](https://www.pv-magazine.com/2024/04/01/potential-effect-of-the-2024-solar-eclipse-on-solar-energy-production/) [Último acceso: Septiembre 2024].
- [12] M. Petty, «"NREL Shows Live Grid Impacts From Total Solar Eclipse", NREL,» 8 Abril 2024. [En línea]. Available: [https://www.nrel.gov/news/program/2024/nrel-shows-live-grid-impacts-from-the-total-solar-eclipse.html.](https://www.nrel.gov/news/program/2024/nrel-shows-live-grid-impacts-from-the-total-solar-eclipse.html) [Último acceso: Septiembre 2024].
- [13] E. Bellini, «"Dutch agency investigates cybersecurity of PV inverters after hack", PV Magazine,» 6 Septiembre 2022. [En línea]. Available: [https://www.pv-magazine.com/2022/09/06/dutch-agency-investigates-cybersecurity-of-pv-inverters-after-hack/.](https://www.pv-magazine.com/2022/09/06/dutch-agency-investigates-cybersecurity-of-pv-inverters-after-hack/) [Último acceso: Septiembre 2024].

- [14] B. Hubert, «"The gigantic and unregulated power plants in the cloud", Berthub.eu,» 19 Agosto 2024. [En línea]. Available: <https://berthub.eu/articles/posts/the-gigantic-unregulated-power-plants-in-the-cloud/>. [Último acceso: Septiembre 2024].
- [15] ArcGISPro, «"Cómo funciona Calcular precisión para la detección de objetos",» [En línea]. Available: <https://pro.arcgis.com/es/pro-app/latest/tool-reference/image-analyst/how-compute-accuracy-for-object-detection-works.htm>. [Último acceso: Septiembre 2024].
- [16] M. M. Jordan, K. Bradbury, L. M. Collins y R. G. Newell, «Automatic Detection of Solar Photovoltaic Arrays in High Resolution Aerial Imagery,» *Applied Energy*, vol. 183, pp. 229-240, <https://doi.org/10.1016/j.apenergy.2016.08.191>, 2016.
- [17] J. M. Malof, L. M. Collins, K. Bradbury y R. G. Newell, «A Deep Convolutional Neural Network and a Random Forest Classifier for Solar Photovoltaic Array Detection in Aerial Imagery,» *2016 IEEE International Conference on Renewable Energy Research and Applications (ICRERA)*, pp. 650-654, <https://doi.org/10.1109/ICRERA.2016.7884415>, 2016.
- [18] C. . N. Clark y F. Pacifici, «A solar panel dataset of very high-resolution satellite imagery to support the Sustainable Development Goals,» *Nature Sci Data*, vol. 10, nº 636, <https://doi.org/10.1038/s41597-023-02539-8>, 2023.
- [19] J. Yu, Z. Wang, A. Majumdar y R. Rajagopal, «DeepSolar: A Machine Learning Framework to Efficiently Construct a Solar Deployment Database in the United States,» *Joule*, vol. 2, nº 12, pp. 2605-2617, <https://doi.org/10.1016/j.joule.2018.11.021>, 2018.
- [20] S. Aizcorbe Pardo, R. C. T. D. de las Cuevas Turel, Z. He y S. Hidalgo López, «Detection of Solar Panels in Satellite Images,» *UC3M*, 2022.
- [21] ITJ, «"Adjudicación del primer Nudo de Transición Justa: El Nudo Mudéjar",» [En línea]. Available: <https://www.transicionjusta.gob.es/es-es/Paginas/Adjudicaci%C3%B3n-del-Nudo-Mud%C3%A9jar-de-Transici%C3%B3n-Justa.aspx>. [Último acceso: Septiembre 2024].
- [22] BOE, «Orden TED/1146/2022, de 21 de noviembre, por la que se resuelve el concurso público para la concesión de capacidad de acceso de evacuación a la red de transporte de energía eléctrica de instalaciones de generación de procedencia renovable...,» 2022.
- [23] ITJ, «"Transición justa en Aragón",» 2023.
- [24] ITJ, «La Transición Justa,» [En línea]. Available: https://www.transicionjusta.gob.es/es-es/Paginas/La_Transicion_Justa/TransicionJusta.aspx. [Último acceso: Septiembre 2024].
- [25] ITJ, «CTJ Aragón (Teruel y Zaragoza),» [En línea]. Available: <https://www.transicionjusta.gob.es/es-es/Paginas/CTJ-Arag%C3%B3n.aspx>. [Último acceso: Septiembre 2024].
- [26] INE, «Cifras oficiales de población de los municipios españoles en aplicación de la Ley de Bases del Régimen Local (Art. 17). Teruel: Población por municipios y sexo.,» 2023. [En línea]. Available: <https://ine.es/jaxiT3/Datos.htm?t=2899>. [Último acceso: Septiembre 2024].
- [27] INE, «Cifras oficiales de población de los municipios españoles en aplicación de la Ley de Bases del Régimen Local (Art. 17). Zaragoza: Población por municipios y sexo.,» 2023. [En línea]. Available: <https://ine.es/jaxiT3/Datos.htm?t=2907>. [Último acceso: Agosto 2024].

ANEXO A. ENTORNO DE TRABAJO Y REPOSITORIO

La herramienta desarrollada para la detección de instalaciones fotovoltaicas y la estimación de su generación energética ha sido implementada en un entorno de Python utilizando Jupyter Notebook como plataforma principal de desarrollo. A lo largo del proyecto, se han utilizado varias APIs y librerías especializadas, lo que ha requerido la integración de diferentes tecnologías y servicios externos. A continuación, se describe el entorno y los principales componentes utilizados.

- Conexión con la API de Google Maps Static para la descarga de imágenes

El primer paso en el proceso fue la obtención de imágenes aéreas de alta resolución a través de la API de Google Maps Static.

Se integró la API utilizando solicitudes HTTP. Se utilizaron parámetros como la latitud, longitud, nivel de zoom, y el tamaño de las imágenes para descargar las áreas geográficas definidas en formato PNG.

Se automatizó el proceso de descarga de imágenes a través de scripts en los que, dado un conjunto de coordenadas, se solicitaban y guardaban las imágenes correspondientes, lo que facilitó la obtención de los datos de entrada para el modelo de detección.

- Inferencia con Roboflow mediante Docker Desktop para la detección de instalaciones fotovoltaicas

Una vez descargadas las imágenes, el siguiente paso fue procesarlas para detectar las instalaciones fotovoltaicas utilizando un modelo de machine learning preentrenado en Roboflow. Para gestionar el entorno de inferencia y procesamiento, se utilizó Docker Desktop, lo que permitió una implementación ágil del modelo en un contenedor independiente.

Se desplegó un contenedor de Docker Desktop que ejecuta el modelo de detección proporcionado por Roboflow. El contenedor se configuró para cargar las imágenes descargadas previamente y realizar la inferencia de detección, generando salidas con las coordenadas y áreas de las instalaciones detectadas.

A través de la API de Roboflow y con la ayuda de Docker, se ejecutaron las inferencias de manera eficiente, procesando las imágenes en lotes y obteniendo las predicciones necesarias para los siguientes pasos del análisis.

- Conexión con la API de PVGIS para la descarga de un TMY

Para la estimación de la generación energética de las instalaciones detectadas, se recurrió a datos meteorológicos históricos. Estos datos fueron obtenidos a través de la API de PVGIS, que proporciona un año meteorológico tipo como base para simular el comportamiento de los sistemas en el tiempo.

La API de PVGIS se integró mediante solicitudes HTTP, donde se solicitaron los datos climáticos históricos para las coordenadas de interés. Los datos descargados incluyeron información sobre radiación solar, temperatura ambiente, y otros factores meteorológicos que influyen en la generación de energía fotovoltaica.

Se creó un flujo automatizado que permite obtener los datos meteorológicos necesarios para cada instalación detectada, facilitando el análisis a gran escala de múltiples áreas.

- Estimación de la generación con el modelo ModelChain de PVLib

Finalmente, se utilizó la librería PVLib para modelar la generación de energía de las instalaciones fotovoltaicas. Se implementó un ModelChain de PVLib, que permite simular el rendimiento de los sistemas fotovoltaicos a partir de los datos de irradiancia y meteorológica obtenidos de PVGIS.

Se configuró el modelo utilizando parámetros de referencia tales como la orientación, inclinación, eficiencia del módulo, eficiencia del inversor y pérdidas del sistema. Se utilizó un modelo de temperatura específico para instalaciones residenciales.

A partir de los datos meteorológicos obtenidos y el área de las instalaciones detectadas y los parámetros definidos, se simuló la generación energética para un año típico. Los resultados incluyeron la estimación de la energía generada, teniendo en cuenta las variaciones diarias y estacionales.

El entorno de desarrollo de la herramienta se ha basado en la flexibilidad y potencia de Python y Jupyter Notebook, permitiendo la integración de diferentes servicios externos que han asegurado que el proceso de detección y estimación energética se ejecute de manera eficiente y precisa.

En el siguiente link se facilita el acceso al repositorio de GITHUB donde se aloja la herramienta y otros archivos relativos al proyecto:

<https://github.com/mabaisa/pv-detection-generation>

ANEXO B. CÓDIGO

Carpeta del proyecto y almacenaje de ficheros

```
# Importing required modules
import numpy as np
import pandas as pd
import utm
import requests
import os

# Project folder and file paths

# Define the name of the project folder and create it in case it
# does not exist yet
folder = "name_of_project_folder"

if not os.path.exists(folder):
    os.makedirs(folder)

print(f"The project will be saved in the folder: '{folder}'")

# Define the center coordinates of the project
latitud = 40.801706
longitud = -0.839873
print(f"The center coordinates of the project are the following: Lat
'{latitud}', Lon '{longitud}'")

# Define the coordinates file name and path
file_name_coord = "coordinates_gmaps.csv"
file_path_coord = os.path.join(folder, file_name_coord)

# Define the roboflow results file name and path
file_name_results = "detections_rf.csv"
file_path_results = os.path.join(folder, file_name_results)

# Define the weather file name and path
file_name_weather = "weather_pvgis.csv"
file_path_weather = os.path.join(folder, file_name_weather)

# Define the pdc prediction file name and path
file_name_predictions_pdc = "predictions_pdc.csv"
file_path_predictions_pdc = os.path.join(folder,
file_name_predictions_pdc)

# Define the eac prediction file name and path
file_name_predictions_eac = "predictions_pvlib_180_10.csv"

file_path_predictions_eac = os.path.join(folder,
file_name_predictions_eac)
```

Barrido imágenes GOOGLE MAPS STATIC

Definición de mallado y coordenadas

```
# Python program to get google maps images of a specified location
# and a given area using
# Google Static Maps API
```

```
# Define zoom and size of the images
zoom = 19 # zoom level
size = "400x400" # image size
api_key_gmaps = "api_key_gmaps" # enter your api key here

# Define center coordinates of the grid, equidistant from all edges
of the grid
latitud = latitud
longitud = longitud
print(f"The center coordinates of the grid are the following: Lat
'{latitud}', Lon '{longitud}'")

# Define area of the grid and related parameters
area_km2 = 1
area_m2 = area_km2 * 1000000
print(f"The defined area of the grid is '{area_km2}' km2")

square_size = 95 # depends on the zoom level of the image, defined
in meters, measured in GMAPS (zoom 19 - size 95m)
grid_size = int(np.ceil((np.sqrt(area_m2) / square_size)))
num_images = np.square(grid_size) # Number of images for downloading
and processing
area_evaluated_km2 = np.square(square_size * grid_size) / 1000000

print(f"The grid size is '{grid_size}' and the total number of
images for processing will be '{num_images}'")

print(f"The total area evaluated is '{area_evaluated_km2}' km2")

# Function to determine the grid coordinates depending on the
desired sweep area

def crear_cuadrícula(x_centro, y_centro, square_size, grid_size):
    # Calcular el desplazamiento para la cuadrícula
    desplazamiento = square_size * (grid_size // 2)

    # List to save the square centers
    centros = []

    # Loop to generate the grid square centers
    for i in range(grid_size):
        for j in range(grid_size):
            # Calculate the coordinates of the grid square centers
            x = x_centro + (i - (grid_size // 2)) * square_size
            y = y_centro + (j - (grid_size // 2)) * square_size

            # Save the coordinates of the grid square centers
            centros.append((x, y))

    return centros

# Obtaining UTM coordinates from the center of the defined main
square
utmcoord = utm.from_latlon(latitud, longitud)
x_centro = utmcoord[0] # Primer valor del resultado (coordenada x)
y_centro = utmcoord[1] # Segundo valor del resultado (coordenada y)

# Obtaining UTM coordinates of the grid square centers
centros_cuadrícula_utm = crear_cuadrícula(x_centro, y_centro,
square_size, grid_size)
```



```
# print(centros_cuadrícula_utm)
print(f"The UTM coordinates of the grid images have been
calculated")

# Function to convert UTM coordinates to latitude and longitude
def utm_a_latlon(x_utm, y_utm):
    # Define UTM zone and hemispheric letter
    zona_utm = 30
    letra_hemisferica = 'T'

    lat, lon = utm.to_latlon(x_utm, y_utm, zona_utm,
                             letra_hemisferica)

    return lat, lon

# Convert UTM coordinates to latitude and longitude
centros_cuadrícula_latlon = [utm_a_latlon(x_utm, y_utm) for x_utm,
y_utm in centros_cuadrícula_utm]
# print(centros_cuadrícula_latlon)
print(f"The Lat, Lon coordinates of the grid images have been
calculated")

# Save the coordinates grid square centers
coordinates = centros_cuadrícula_latlon

# Create the coordinates DataFrame
data_coord = {
    'center_lat': [latitud] * len(coordinates),
    'center_lon': [longitud] * len(coordinates),
    'image': [f'image_{i}' for i in range(len(coordinates))],
    'lat': [coord[0] for coord in coordinates],
    'lon': [coord[1] for coord in coordinates]
}
df_coord = pd.DataFrame(data_coord)

print(f"The coordinates dataframe has been created")
print(df_coord)
```

Almacenar fichero de coordenadas

```
# Save the coordinates DataFrame

# Save the DataFrame in a CSV in its file path
df_coord.to_csv(file_path_coord, index=False)

print(f"CSV file saved in '{folder}/{file_name_coord}'")
```

Descarga de imágenes API GMAPS STATIC

```
# Function to download images for each of the grid center
def download_images_for_grid(coordinates, zoom, size,
api_key_gmaps):

    url = "https://maps.googleapis.com/maps/api/staticmap"
    for i, coord in enumerate(coordinates):
        center = f"{coord[0]}, {coord[1]}"
        r =
requests.get(f'{url}?center={center}&zoom={zoom}&size={size}&maptype
=satellite&key={api_key_gmaps}')
        image_path = os.path.join(folder, f'image_{i}.png')
        with open(image_path, 'wb') as f:
            f.write(r.content)

# Download images for each of the grid center
download_images_for_grid(coordinates, zoom, size, api_key)

print(f"Images saved in '{folder}')
```

Detección Roboflow

Definición del modelo

```
# Importing required modules
import matplotlib.pyplot as plt
from skspatial.objects import Vector, Point
from skspatial.measurement import area_signed
from inference_sdk import InferenceHTTPClient,
InferenceConfiguration
import supervision as sv
import cv2

# https://docs.roboflow.com/deploy/hosted-api/custom-models/object-
detection
# https://universe.roboflow.com/whereareyousolarpanel/solar-pv-
panel-detection/model/3

API_KEY_ROBOFLOW = "api_key_roboflow"
THRESHOLD = 0.7

# 0-Instalar Docker Desktop
https://docs.docker.com/desktop/install/windows-install/
# 1-Abrir Docker (cerrar asegurandose que sigue en segundo plano
(icono presente))
# 2-Lanzar máquina virtual desde cmd: inference server start
# 3-Lanzar script

client = InferenceHTTPClient(
    api_url="http://localhost:9001", # Opción docker desktop
    #api_url="https://detect.roboflow.com" -> Acceso a RoboFlow
    hosted, opción de pago (1000 detecciones/mes)
    api_key=API_KEY_ROBOFLOW
)

client.configure(InferenceConfiguration(confidence_threshold=THRESHO
LD))
```

```
def process_image(file_image):
    results = client.infer(file_image, model_id="solar-pv-panel-
detection/3")
    labels = [item["class"] for item in results["predictions"]]
    detections = sv.Detections.from_inference(results)
    label_annotator = sv.LabelAnnotator()
    mask_annotator = sv.MaskAnnotator() # MaskAnnotator: draw mask -
BoundingBoxAnnotator: draw bounding box

    image = cv2.imread(file_image) # to read local file
    annotated_image = mask_annotator.annotate(scene=image,
detections=detections)
    # annotated_image =
    label_annotator.annotate(scene=annotated_image,
detections=detections, labels=labels)

    # Save annotated image
    output_image_path = f"{os.path.splitext(file_image)[0]}_w.png" #
w for written (annotated) image
    cv2.imwrite(output_image_path, annotated_image)
    print(f"Processed {file_image}, saved annotated image to
{output_image_path}")

    return results, detections

print(f"Ready for image processing")
```

Procesado de imágenes

```
# Process multiple images locally saved
# DataFrame to save results
df_results_rf = pd.DataFrame(columns=["image_name", "coordinates",
"area_rf", "orientation_rf"])

for i in range(num_images):
    file_image = os.path.join(folder, f"image_{i}.png")
    if os.path.exists(file_image):
        results, detections = process_image(file_image)

        for idx, prediction in enumerate(results['predictions']):
            points = pd.DataFrame(prediction['points'])

            pto_max_x = points.iloc[points.idxmax().x]
            pto_max_y = points.iloc[points.idxmax().y]
            pto_min_x = points.iloc[points.idxmin().x]
            pto_min_y = points.iloc[points.idxmin().y]

            dist_xmax_ymax = Point([pto_max_x.x,
pto_max_x.y]).distance_point([pto_max_y.x, pto_max_y.y])
            dist_xmax_ymin = Point([pto_max_x.x,
pto_max_x.y]).distance_point([pto_min_y.x, pto_min_y.y])

            v1 = Vector.from_points([pto_max_x.x, pto_max_x.y],
[pto_max_y.x, pto_max_y.y])

            if dist_xmax_ymax < dist_xmax_ymin:
                v1 += 90
```

```
orientation_rf = 180 + np.degrees(v1.angle_signed([0,
1])) # to use the orientation estimated geometrically

area_rf = detections.area[idx]

# Create a temporary DataFrame for new row
df_temp = pd.DataFrame([
    "image_name": file_image,
    "coordinates": coordinates[i],
    "area_rf": area_rf,
    "orientation_rf": orientation_rf,
])

# Concat temporary DataFrame with main df
df_results_rf = pd.concat([df_results_rf, df_temp],
ignore_index=True)

# print(f"Image: {file_image}, Coordinates:
{coordinates[i]}°, Area: {area_rf} m2")
else:
    print(f"File {file_image} does not exist")

print(f"The Roboflow results dataframe has been created")

# Show the results DataFrame
print(df_results_rf)

# print (results)
# print (detections)
```

Almacenar fichero de resultados

```
# Save the Roboflow results DataFrame

# Save the DataFrame in a CSV in its file path
df_results_rf.to_csv(file_path_results, index=False)

print(f"CSV file saved in '{folder}/{file_name_results}')
```

Estimación generación PVLIB

Definición de parámetros

```
import pvlib
from pvlib.pvsystem import PVSystem, Array, FixedMount
from pvlib.location import Location
from pvlib.modelchain import ModelChain

timezone = 'Europe/Madrid'
```

```
temperature_model_parameters =
pvlib.temperature.TEMPERATURE_MODEL_PARAMETERS['sapm']['insulated_back_glass_polymer'] #change temperature if desired
# insulated_back_glass_polymer
# open_rack_glass_polymer
# open_rack_glass_glass
# close_mount_glass_glass

module_eff = 0.2
gamma = -0.004 # module temperature coefficient for Power loss reduction
eta_inv = 0.98 # inverter efficiency
system_loss = 0.15 # general system losses (dust, electrical, mismatch, shadowing ...)

area_ratio = 23.3 # Ratio between the output area of roboflow and the measured area in GMAPS, pixels/m

orientation_deg = 180
inclination_deg = 10

print(f"Pv parameters set")
```

Estimación de la potencia instalada

```
# Duplicate results DataFrame from Roboflow
#df_predictions_pdc = df_results_rf #copy df
df_predictions_pdc = pd.read_csv(file_path_results) #import df locally saved

# Add columns for area in m2 and installed pdc
df_predictions_pdc["area_m2"] = 0.0
df_predictions_pdc["pdc_kw"] = 0.0

# Define for each row the area and pdc
for idx, row in df_predictions_pdc.iterrows():
    df_predictions_pdc.at[idx, "area_m2"] =
df_predictions_pdc.at[idx, "area_rf"] / area_ratio
    df_predictions_pdc.at[idx, "pdc_kw"] =
df_predictions_pdc.at[idx, "area_m2"] * module_eff

print(f"The prediction results dataframe with Pdc has been created")

# Show the DataFrame results for installed pdc
print(df_predictions_pdc)
```

Almacenar fichero pdc

```
# Save the Pdc predictions DataFrame
# Save the DataFrame in a CSV in its file path
df_predictions_pdc.to_csv(file_path_predictions_pdc, index=False)

print(f"CSV file saved in '{folder}/{file_name_predictions_pdc}'")
```

Descarga de datos meteorológicos de PVGIS

```
weather_pvgis = pvlib.iotools.get_pvgis_tmy(latitude, longitude)[0]
#print (weather_pvgis)
print(f"weather data from PVGIS has been downloaded")
```

Almacenar fichero meteo

```
# Save the PVGIS weather data

# Save the DataFrame in a CSV in its file path
weather_pvgis.to_csv(file_path_weather)

print(f"CSV file saved in '{folder}/{file_name_weather}'")
```

Estimación energética

```
# Duplicate DataFrame with results from pdc
df_predictions_eac = df_predictions_pdc #copy df
df_predictions_eac = pd.read_csv(file_path_predictions_pdc) #import
df locally saved

# weather_imp = pd.read_csv(file_path_weather) # import pvgis file

# Add columns for orientation, inclination and annual energy
df_predictions_eac["orientation_deg"] = orientation_deg #change for
orientation_rf if desired
df_predictions_eac["inclination_deg"] = inclination_deg
df_predictions_eac["annual_energy_kwh"] = 0.0

for idx, row in df_predictions_eac.iterrows():

    #latitude, longitude = row["coordinates"]
    surface_tilt = row["inclination_deg"]
    surface_azimuth = row["orientation_deg"]
    pdc = row["pdc_kw"]

    module = {'pdc0': pdc, 'gamma_pdc': gamma}
    inverter = {'pdc0': pdc, 'eta_inv_nom': eta_inv}

    location = Location(
        latitude=latitude, #coordinates from the center of GMAPS
sweep
        longitude=longitude,
        tz=timezone,
    )

    #weather = pvlib.iotools.get_pvgis_tmy(latitude, longitude)
    #If this option is used, many pvgis queries are made and for a
small area it is better to take only the center of the main square
coordinates

    weather = weather_pvgis # need to run the apicorrer la api
    #weather = weather_imp #import df saved, not working by now
```



```
mount = FixedMount(surface_tilt=surface_tilt,
surface_azimuth=surface_azimuth)

array = Array(
    mount=mount,
    module_parameters=module,
    temperature_model_parameters=temperature_model_parameters,
)

system = PVSystem(arrays=[array], inverter_parameters=inverter)

mc = ModelChain(system, location, aoi_model='physical',
spectral_model='no_loss')
mc.run_model(weather)

annual_energy_kwh = mc.results.ac.sum() * (1 - system_loss)

df_predictions_eac.at[idx, "annual_energy_kwh"] =
annual_energy_kwh

print(f"The prediction results dataframe with annual Eac has been
created")

# Show the DataFrame with annual energy results
print(df_predictions_eac)
```

Almacenar fichero Eac

```
# Save the PVlib predictions DataFrame

# Save the DataFrame in a CSV in its file path
df_predictions_eac.to_csv(file_path_predictions_eac, index=False)

print(f"CSV file saved in '{folder}/{file_name_predictions_eac}')
```

ÍNDICE DE FIGURAS

Figura 1. Evolución de la potencia de autoconsumo instalada (MW)	2
Figura 2. Itinerario de la Hoja de Ruta del Autoconsumo para el periodo 2021-2030	3
Figura 3. Promedio horario de la demanda en España 2018-2023 (MWh).....	4
Figura 6. Ilustración de una curva PR.....	15
Figura 4. Arquitectura de detección en cascada empleada en el trabajo “A deep convolutional neural network and a random forest classifier for solar photovoltaic array detection in aerial imagery”.	16
Figura 5. Proceso de partición y anotación de datos en el trabajo “A solar panel dataset of very high-resolution satellite imagery to support the Sustainable Development Goals”.	16
Figura 7. DeepSolar. Un marco de aprendizaje automático para construir eficientemente una base de datos de despliegue solar en Estados Unidos.....	17
Figura 8. Metodología de entrenamiento y evaluación del proyecto “Detection of Solar Panels in Satellite Images UC3M”.	18
Figura 9. Evaluación de modelos de detección de instalaciones fotovoltaicas.....	21
Figura 10. Imagen aérea de la ubicación del área de evaluación del proyecto, resaltada en rojo	22
Figura 11. Imágenes ampliadas del área de evaluación del proyecto	22
Figura 12. Curva PR para distintos niveles de zoom, variando el nivel de threshold del modelo.	24
Figura 13. F1 para distintos niveles de zoom, variando el nivel de threshold del modelo.	24
Figura 14. Ejemplo de desempeño del modelo de detección para un Zoom 18.....	25
Figura 15. Ejemplo de desempeño del modelo de detección para un Zoom 19.....	25
Figura 16. Ejemplo de desempeño del modelo de detección para un Zoom 20.....	26
Figura 17. Histograma de potencia de las instalaciones fotovoltaicas detectadas.	28
Figura 18. Delimitación del ámbito territorial del CTJA.	32
Figura 19. Área evaluada en el ámbito territorial del CTJA.	34

ÍNDICE DE TABLAS

Tabla 1. Comparativa de proveedores de imágenes aéreas.....	8
Tabla 2. Clases y predicciones de los modelos de detección.....	13
Tabla 3. Número de positivos verdaderos, positivos falsos y negativos falsos en función del nivel de zoom de las imágenes y el threshold del modelo.....	23
Tabla 4. Métricas de precisión, recall y F1 en función del nivel de zoom de las imágenes y el threshold del modelo.....	23
Tabla 5. Estimación de la potencia instalada en función de la eficiencia del módulo fotovoltaico.....	28
Tabla 6. Parámetros de referencia.....	29
Tabla 7. Energía anual en función de la orientación y la inclinación.	30
Tabla 8. Producción específica en función de la orientación y la inclinación	30
Tabla 9. Estimación energética en función del coeficiente de temperatura.	30
Tabla 10. Estimación energética en función del coeficiente de la eficiencia del inversor.....	31
Tabla 11. Estimación energética en función de las pérdidas del sistema.....	31
Tabla 12. Parámetros de referencia del modelo de generación para el caso de estudio.....	35
Tabla 13. Resultados de la detección y la estimación de la generación de las instalaciones fotovoltaicas ubicadas en los municipios del CTJA.....	36

LISTA DE ACRÓNIMOS

API: Application Programming Interface
APPA: Asociación de Empresas de Energías Renovables
CNN: Convolutional Neural Network
CTJA: Convenio de Transición Justa de Aragón
DL: Deep Learning
FN: False Negative
FP: False Positive
GW: Gigavatio
GWh: Gigavatio-hora
kW: Kilovatio
kWh: Kilovatio-hora
kWp: Kilovatio pico
MITECO: Ministerio para la Transición Ecológica y el Reto Demográfico
ML: Machine Learning
MW: Megavatio
MWh: Megavatio-hora
NREL: National Renewable Energy Laboratory
ODS: Objetivos de Desarrollo Sostenible
PNIEC: Plan Nacional Integrado de Energía y Clima
RADNE: Registro Administrativo de Autoconsumo de Energía Eléctrica
REE: Red Eléctrica de España
RF: Random Forest
TN: True Negative
TMY: Typical Meteorological Year
TP: True Positive
UE: Unión Europea
UNEF: Unión Española Fotovoltaica
YOLO: You Only Look Once